

România
Ministerul Apărării Naționale
Academia Tehnică Militară "Ferdinand I"

Facultatea de Sisteme Informactice și Securitate Cibernetică
Specializarea Absolvită



Soluție inteligentă de analiză a înregistrărilor video

Coordonator Științific

Grad Prenume NUME

Absolvent

Grad Dumitru Estera

Conține _____ file
Inventariat sub numărul _____
Cu poziția din indicator _____
Cu termen de păstrare _____

București
2026

Mulțumiri pentru persoanele care au sprijinit procesul de realizare a acestei lucrări

Referatul Coordonatorului Științific

Referatul reprezintă un text în care coordonatorul științific sumarizează, ulterior finalizării conținutului efectiv, efortul pe care l-ați depus și trage concluzii cu privire la gradul de realizare a obiectivelor propuse inițial (cele prezentate în cadrul detalierii). De regulă, acest referat nu depășește cele 4 pagini alocate în acest document.

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

Tema Proiectului de Diplomă

Tema proiectului de diplomă (sau detalierea) reprezintă un text realizat de coordonatorul științific, în lunile următoare propunerii titlului proiectului de diplomă către facultate, în care detaliază nevoia reală a implementării unui astfel de proiect și modul în care se dorește a fi implementat. În plus, poate prezenta structura pe capitole a viitoarei lucrări, anexele ce vor fi incluse și sursele bibliografice din care studentul se va informa. De regulă, această detaliere nu depășește cele 4 pagini alocate în acest document.

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

NECLASIFICAT

Abstract

This is the abstract of the thesis, written after finishing all the other components of the document (especially the chapters). It broadly presents the objectives and the achievements of the thesis. It is present in both Romanian and English.

Rezumat

Acesta este rezumatul lucrării, realizat după finalizarea tuturor celorlaltor componente ale documentului (în special capitolele). El prezintă, în linii mari, obiectivele și realizările lucrării. Este prezent atât în limba română, cât și în cea engleză.

Cuprins

1	Introducere	1
1.1	Contextul actual al supravegherii video	1
1.2	Motivația alegerii temei	1
1.3	Problema abordată	1
1.4	Obiectivele lucrării	1
1.5	Contribuții personale	1
1.6	Structura lucrării	1
2	Stadiul Actual al Sistemelor Inteligente de Supraveghere Video	2
2.1	Evoluția sistemelor de supraveghere video	2
2.2	Soluții comerciale existente	2
2.3	Soluții open-source și academice	2
2.4	Stadiul cercetării în domeniile relevante	2
2.5	Plasarea proiectului în context	2
3	Fundamente Teoretice	3
3.1	Învățarea profundă pentru viziune artificială	4
3.1.1	Rețele neuronale convoluționale (CNN)	4
3.1.2	Arhitecturi de referință	4
3.1.3	Funcții de pierdere și regularizare	4
3.2	Detecția obiectelor	4
3.2.1	Familia YOLO	4
3.2.2	YOLOv8	4
3.2.3	YOLOv10	4
3.2.4	Metrici de evaluare	4
3.3	Recunoașterea facială	4
3.3.1	Detecția fețelor	4
3.3.2	Embeddings faciale	4
3.3.3	Funcția de pierdere ArcFace	4
3.3.4	Arhitectura MobileFaceNet (w600k_mbf)	4
3.3.5	InsightFace și pachetul buffalo_s	4
3.4	Analiza demografică și a emoțiilor	4
3.4.1	Recunoașterea expresiilor faciale	4
3.4.2	Mini-Xception	4

3.5	Recunoașterea optică a caracterelor	4
3.5.1	Detectia zonelor de text – CRAFT	4
3.5.2	Recunoașterea caracterelor – CRNN	4
3.6	Recunoașterea acțiunilor în videoclipuri	4
3.6.1	Provocările analizei temporale	4
3.6.2	Arhitectura SlowFast	4
3.6.3	PyTorchVideo	4
3.7	Procesarea imaginilor – tehnici clasice utilizate	4
3.8	Căutarea în spații vectoriale	4
3.8.1	Biblioteca FAISS	4
3.9	Tehnologii utilizate pentru aplicația web	4
3.9.1	FastAPI	4
3.9.2	Protocolul WebSocket	4
3.9.3	React și ecosistemul frontend	4
3.9.4	Codificarea Base64 a cadrelor video	4
4	Analiza Cerințelor și Proiectarea Sistemului	5
4.1	Analiza cerințelor	5
4.1.1	Cerințe funcționale	5
4.1.2	Cerințe non-funcționale	9
4.2	Cazuri de utilizare	10
4.3	Arhitectura generală a sistemului	15
4.3.1	Modelul client-server	16
4.3.1.1	Clientul	16
4.3.1.2	Serverul	16
4.3.1.3	Sursele video	17
4.3.1.4	Persistența	17
4.3.2	Diagrama de componente	17
4.3.3	Diagrama de implementare (deployment)	21
4.3.3.1	Nodul client (browser)	21
4.3.3.2	Nodul server cu GPU	21
4.3.3.3	Nodul bază de date	21
4.3.3.4	Camere IP	21
4.4	Proiectarea pipeline-ului multi-threaded	22
4.4.1	Cele 7 fire de execuție	24
4.4.1.1	Firul 1 – Captura video	24
4.4.1.2	Firul 2 – Recunoaștere facială și analiză demo- grafică	24
4.4.1.3	Firul 3 – Plăcuțe de înmatriculare	24
4.4.1.4	Firul 4 – Foc și fum	24
4.4.1.5	Firul 5 – Recunoaștere acțiuni umane	25
4.4.1.6	Firul 6 – Arme	25
4.4.1.7	Firul 7 – Fuziune	25
4.4.1.8	Justificarea separării	25
4.4.2	Mecanismele de sincronizare	26
4.4.2.1	Cozi thread-safe	26

4.4.2.2	Partajarea cadrului curent	26
4.4.2.3	Mecanismul <i>ultimul cadru disponibil</i>	27
4.4.2.4	Stare partajată protejată prin lock-uri	27
4.4.3	Justificarea procesării paralele	27
4.4.3.1	Utilizarea GPU-ului	27
4.4.3.2	Măsurarea latențelor de inferență	27
4.4.3.3	Latența percepută per modul	29
4.4.3.4	Dezactivarea selectivă	29
4.4.3.5	Tolerare la eșec	29
4.4.3.6	De ce nu microservicii separate	29
4.5	Proiectarea API-ului REST	30
4.5.1	Convenții de denumire	30
4.5.2	Catalogul endpoint-urilor pe categorii	30
4.5.3	Structura răspunsurilor	34
4.5.4	Coduri de eroare	34
4.6	Proiectarea canalului WebSocket	35
4.6.1	Endpoint dedicat pentru streaming	35
4.6.2	Formatul mesajelor	35
4.6.3	Cadența de transmitere	36
4.6.4	Heartbeat și detectarea deconectării	38
4.6.5	Reconectare	38
4.7	Proiectarea bazei de date	38
4.7.1	Alegerea sistemului de baze de date	38
4.7.2	Diagrama entitate-relație	39
4.7.3	Tabelele principale	41
4.7.4	Chei primare și străine	42
4.7.5	Indexarea	42
4.8	Proiectarea sistemului de control al accesului	43
4.8.1	Modelul RBAC	43
4.8.2	Matricea de permisiuni	44
4.8.3	Hashing-ul parolelor	44
4.8.4	Gestiunea sesiunii (JWT)	45
4.9	Proiectarea logicii de alarmare	46
4.9.1	Reguli de declanșare	46
4.9.2	Captura asociată (snapshot)	47
4.9.3	Niveluri de severitate și mapping pe tipuri de evenimente	47
4.9.4	Deduplicarea temporală	47
4.10	Proiectarea interfeței utilizator	50
4.10.1	Structura de navigare	50
4.10.2	Principii UX	50
5	Implementarea Modulelor de Inteligență Artificială	52
5.1	Modulul de recunoaștere facială	52
5.1.1	Detecția fețelor și extragerea embeddings-urilor	52
5.1.1.1	Configurarea execuției pe GPU	53
5.1.1.2	Gestionarea bibliotecilor CUDA și a TensorFlow	53

5.1.1.3	Înregistrarea persoanelor	54
5.1.2	Indexarea cu FAISS FlatL2	54
5.1.2.1	Maparea identităților	54
5.1.2.2	Persistența și reconstrucția indexului	54
5.1.2.3	Siguranța accesului concurent	55
5.1.3	Strategia de matching	55
5.1.3.1	De la distanța L2 la similaritatea cosinus	55
5.1.4	Optimizarea: omiterea analizei demografice pentru fețele cunoscute	56
5.2	Analiza demografică și emoțională	56
5.2.1	Estimarea vârstei și genului	56
5.2.2	Recunoașterea emoțiilor cu Mini-Xception	57
5.2.3	Preprocesarea crop-ului facial	57
5.2.4	Inferența pe CPU	58
5.3	Modulul de recunoaștere a plăcuțelor de înmatriculare	58
5.3.1	Detecția plăcuțelor cu YOLOv8	59
5.3.2	Up-scaling-ul plăcuțelor mici	59
5.3.3	Pipeline-ul de preprocesare pentru OCR	60
5.3.4	Apelul EasyOCR	60
5.3.5	Fallback pe imaginea color	61
5.3.6	Tracking-ul plăcuțelor între cadre	61
5.3.7	Validarea formatului	61
5.3.8	Votarea temporală	62
5.4	Modulul de detecție foc și fum	62
5.4.1	Modelul YOLOv10 pre-antrenat	63
5.4.2	Pipeline-ul de filtrare în cinci niveluri	63
5.4.2.1	Praguri de încredere per clasă	63
5.4.2.2	Filtre de dimensiune	63
5.4.2.3	Verificarea cromatică HSV	64
5.4.2.4	Confirmarea temporală prin tracking IoU	64
5.4.2.5	Cooldown de alertă pe locație	65
5.4.3	Flag-urile <i>confirmed</i> și <i>alert</i>	65
5.5	Modulul de detecție a armelor (model fine-tuned propriu)	66
5.5.1	Justificarea unei singure clase <i>weapon</i>	66
5.5.2	Selectarea modelului de bază	66
5.5.3	Dataseturile utilizate	66
5.5.4	Preprocesarea și unificarea	67
5.5.5	Strategia de denumire (<i>zen_</i> / <i>rf_</i>)	67
5.5.6	Parametrii de antrenare	68
5.5.7	Augmentările folosite	68
5.5.8	Rezultatele antrenării	69
5.5.9	Discuție asupra rezultatelor	69
5.6	Modulul de recunoaștere a acțiunilor umane (fine-tuning SlowFast)	69
5.6.1	Justificarea alegerii SlowFast R50	70
5.6.2	Construcția setului de date	70
5.6.2.1	Clasa <i>normal</i>	70

5.6.2.2	Clasa <i>fight</i>	71
5.6.2.3	Clasa <i>vandalism</i> – dataset propriu	71
5.6.2.3.1	Justificarea creării unui dataset propriu.	71
5.6.2.3.2	Etapa 1: Scraping automat YouTube.	71
5.6.2.3.3	Etapa 2: Filtrare manuală.	71
5.6.2.3.4	Etapa 3: Editare în OpenShot.	71
5.6.2.3.5	Setul final.	71
5.6.3	Pregătirea modelului pentru fine-tuning	72
5.6.3.1	Formatul intrării (contractul SlowFast)	72
5.6.4	Parametrii de antrenare	72
5.6.5	Rezultatele	73
5.6.6	Analiza per clasă	73
5.6.6.1	Integrarea în aplicație	74
5.7	Fuziunea rezultatelor pe cadru	74
5.7.1	Dispecerizarea cadrelor și procesarea în paralel	74
5.7.2	Sincronizarea rezultatelor după <i>frame_id</i>	75
5.7.3	Compunerea cadrului adnotat	75
5.7.4	Generarea alarmelor și deduplicarea	75
5.7.5	Difuzarea către clienți prin WebSocket	76
6	Implementarea Aplicației Web	77
6.1	Structura backend-ului FastAPI	78
6.2	Endpoint-ul WebSocket pentru streaming live	78
6.3	Modelul de date și persistența	78
6.4	Sistemul de autentificare	78
6.5	Modulele frontend-ului React	78
6.5.1	Autentificare	78
6.5.2	Vizualizarea live a camerelor (Dashboard)	78
6.5.3	Activarea/Dezactivarea modulelor AI	78
6.5.4	Gestiunea persoanelor (CRUD)	78
6.5.5	Gestiunea zonelor	78
6.5.6	Gestiunea camerelor	78
6.5.7	Gestiunea plăcuțelor de înmatriculare	78
6.5.8	Gestiunea alarmelor	78
6.5.9	Jurnale de activitate	78
6.5.10	Statistici și KPI-uri	78
6.5.11	Gestiunea utilizatorilor	78
6.6	Logica de business pentru declanșarea alertelor	78
6.7	Sincronizarea camerei conectate dinamic cu registrul de camere	78
7	Testarea și Evaluarea Sistemului	79
7.1	Metodologia de testare	79
7.2	Configurația hardware folosită	79
7.3	Evaluarea pipeline-ului integrat	79
7.3.1	FPS la procesare concurrentă	79
7.3.2	Utilizarea memoriei GPU și RAM	79

7.3.3	Latența end-to-end	79
7.4	Scenarii de test funcțional	79
7.5	Discuție asupra false pozitivelor și false negativelor	79
7.6	Limitări observate	79
8	Concluzii și Direcții de Dezvoltare	80
8.1	Sinteza rezultatelor	80
8.2	Obiective atinse vs. obiective propuse	80
8.3	Contribuții originale	80
8.4	Limitări ale soluției actuale	80
8.5	Direcții de dezvoltare viitoare	80
	Bibliografie	81

Listă de figuri

- 4.1 Diagrama use-case UML a sistemului de supraveghere inteligent, cu actorii Administrator și Operator în raport cu cele 10 cerințe funcționale, grupate pe domenii (detectie AI, interacțiune cu utilizatorul, administrare). 8
- 4.2 Diagrama detaliată a cazurilor de utilizare (UC1–UC12), cu actorii Administrator și Operator, cazurile partajate și cele rezervate Administratorului, precum și relațiile **include** (autentificare) și **extend** (rezolvare alarmă). 12
- 4.3 Diagramă bloc de ansamblu a sistemului, organizată pe cele trei straturi logice (Prezentare, Aplicație, Persistență) și protocoalele de comunicare dintre componente: HTTPS/REST și WebSocket între client și backend, RTSP/HTTP/MJPEG pentru fluxurile camerelor, apeluri în proces către modelele AI de pe GPU și acces SQL la PostgreSQL prin driver-ul **psycopg2**. Indexul FAISS este menținut în memoria backend-ului și reconstruit din PostgreSQL la pornire. . . . 16
- 4.4 Diagrama de componente UML a backend-ului. Modulul Captură furnizează cadre (prin interfața *Cadru*) către Modulul AI. Acesta din urmă este o componentă complexă, alcătuită din cele cinci detectoare independente (recunoaștere facială, plăcuțe de înmatriculare, foc/fum, arme și acțiuni umane), care expune contractul comun *Detector* către Modulul Fuziune. Rolul Fuziunii este de a difuza cadrele adnotate către componenta de Gestiune WebSocket și de a salva alarmele și jurnalele generate. În paralel, API-ul REST realizează operațiile de tip CRUD. Ambele componente depind de Nivelul de Persistență, format din baza de date PostgreSQL și indexul FAISS (reconstruit la fiecare pornire). Contractele dintre componente sunt ilustrate vizual prin interfețe de tip *lollipop*. 20

- 4.5 Diagrama de implementare (deployment) UML a sistemului. Nodul *Client (Browser)* – în una sau mai multe instanțe ($\{1..m\}$) – servește aplicația React ca artefact static și comunică cu serverul prin HTTP și WebSocket pe portul 8000. Nodul *Server GPU* găzduiește procesul `app.py` (FastAPI + Uvicorn, cu cele ~ 7 fire de execuție), modelele AI încărcate în VRAM (InsightFace, cele două instanțe YOLOv8 pentru plăcuțe și arme, SlowFast-R50 și modelul de foc/fum) prin `onnxruntime-gpu`, modelul de emoție FER ținut deliberat pe CPU, indexul FAISS în memoria RAM și baza de date **PostgreSQL** (acces prin TCP/SQL pe portul 5432, indexul FAISS fiind reconstruit din ea la pornire). *Camerele IP* (CAM-01..CAM-n, $\{1..n\}$) furnizează fluxuri RTSP/MJPEG/HTTP. 22
- 4.6 Diagrama de flux a pipeline-ului multi-threaded. Cele **șapte fire de execuție** sunt reprezentate ca dreptunghiuri, iar cele unsprezece cozi `queue.Queue(maxsize=10)` ca cilindri. Fluxul cadrelor pornește de sus, de la `CaptureThread` (care, prin `_dispatch_frame`, depune câte o copie `frame.copy()` în cozile de *intrare*), coboară prin cele cinci coloane paralele de fire AI – fiecare adnotat cu latența de inferență măsurată (Tabelul 4.1) – ale căror rezultate converg, prin cozile de *ieșire*, către `MergingThread`. Acesta aplică politica *ultimul cadru disponibil* (folosind `raw_frame_queue` ca *fallback*), declanșează alarmele și difuzează cadrul adnotat prin `_broadcast_frame` în cozile per-client `client_queues`, de unde este preluat de clienții WebSocket. Politica de saturare diferă în funcție de direcția cozii: *omitere* la intrare (cadrul nou este abandonat dacă firul detectorului are deja un backlog) și *drop-oldest* la ieșire (se scoate cel mai vechi rezultat pentru a-l insera pe cel nou). 23
- 4.7 Diagramă de secvență UML a ciclului de viață al unei conexiuni WebSocket: autentificare (validarea token-ului JWT, cu închidere 1008 la eșec), handshake (`accept()`), alocarea cozii proprii în `client_queues`, bucla de transmitere la ~ 30 FPS (firul de fuziune produce prin `_broadcast_frame`, endpoint-ul consumă neblocant și trimite mesajele `video_frame`) și deconectarea, cu eliminarea cozii din dicționar. 37
- 4.8 Diagrama entitate-relație (ERD) a schemei PostgreSQL `facial_recognition`, cu cele zece tabele implementate în `database_manager.py`. Cheile primare (`id`) sunt subliniate, iar cele cinci constrângeri UNIQUE sunt marcate cu asterisc. Liniile punctate evidențiază legăturile logice neimpuse prin FK: cele patru câmpuri `camera_id` către `cameras` și relația persoană-zonă, denormalizată ca atribut multi-valoare `authorized_zones TEXT[]` pe `persons` (nu ca entitate asociativă). Tabelul `users` este independentă. 40

- 4.9 Diagrama de flux a deciziei de alarmare pentru un cadru. Pornind de la rezultatele agregate în firul de fuziune, cele șase verificări sunt evaluate *independent* și secvențial, astfel încât un singur cadru poate genera mai multe alarme. Fiecare ramură stabilește tipul, severitatea și **dedup_subject**, după care alarma trece printr-o poartă comună: cooldown de 30 s pe cheia (**cameră**, **tip**, **subiect**) (sub **alarm_lock**) și un *backstop* în baza de date împotriva duplicatelor recente nerezolvate, înainte de persistare și difuzare în interfață. . . 49

NECLASIFICAT

NECLASIFICAT

Listă de Abrevieri

AI	<i>Artificial Intelligence</i>
API	<i>Application Programming Interface</i>
CNN	<i>Convolutional Neural Network</i>
CPU	<i>Central Processing Unit</i>
CRNN	<i>Convolutional Recurrent Neural Network</i>
FAISS	<i>Facebook AI Similarity Search</i>
FPS	<i>Frames Per Second</i>
GPU	<i>Graphics Processing Unit</i>
HSV	<i>Hue, Saturation, Value</i>
IoU	<i>Intersection over Union</i>
JWT	<i>JSON Web Token</i>
mAP	<i>mean Average Precision</i>
OCR	<i>Optical Character Recognition</i>
ONNX	<i>Open Neural Network Exchange</i>
RBAC	<i>Role-Based Access Control</i>
REST	<i>Representational State Transfer</i>
YOLO	<i>You Only Look Once</i>

NECLASIFICAT

NECLASIFICAT

Capitolul 1: Introducere

- 1.1 Contextul actual al supravegherii video
- 1.2 Motivația alegerii temei
- 1.3 Problema abordată
- 1.4 Obiectivele lucrării
- 1.5 Contribuții personale
- 1.6 Structura lucrării

Capitolul 2: Stadiul Actual al Sistemelor Inteligente de Supraveghere Video

- 2.1 Evoluția sistemelor de supraveghere video
- 2.2 Soluții comerciale existente
- 2.3 Soluții open-source și academice
- 2.4 Stadiul cercetării în domeniile relevante
- 2.5 Plasarea proiectului în context

NECLASIFICAT

Capitolul 3: Fundamente Teoretice

3.1 Învățarea profundă pentru viziune artificială

3.1.1 Rețele neuronale convoluționale (CNN)

3.1.2 Arhitecturi de referință

3.1.3 Funcții de pierdere și regularizare

3.2 Detectia obiectelor

3.2.1 Familia YOLO

3.2.2 YOLOv8

3.2.3 YOLOv10

3.2.4 Metrice de evaluare

3.3 Recunoașterea facială

3.3.1 Detectia fețelor

3.3.2 Embeddings faciale

3.3.3 Funcția de pierdere ArcFace

3.3.4 Arhitectura MobileFaceNet (w600k_mbf)

3.3.5 InsightFace și pachetul buffalo_s

3.4 Analiza demografică și a emoțiilor

3.4.1 Recunoașterea expresiilor faciale

3.4.2 Mini-Xception

3.5 Recunoașterea optică a caracterelor

3.5.1 Detectia zonelor de text – CRAFT

3.5.2 Recunoașterea caracterelor – CRNN

3.6 Recunoașterea acțiunilor în videoclipuri

3.6.1 Detectia și clasificarea acțiunilor

Capitolul 4:

Analiza Cerințelor și Proiectarea Sistemului

4.1 Analiza cerințelor

Înainte de prezentarea arhitecturii și a detaliilor de implementare, este important să fie stabilit în mod clar atât ceea ce trebuie să realizeze sistemul, cât și modul în care acesta trebuie să își îndeplinească funcțiile. În acest sens, secțiunea de față definește cerințele funcționale, care descriu capabilitățile oferite utilizatorului, precum și cerințele nefuncționale, care stabilesc constrângerile și criteriile de calitate ale soluției. Aceste cerințe vor constitui baza pe care se vor fundamenta deciziile de proiectare prezentate în capitolele următoare..

Distincția dintre cele două categorii este esențială: cerințele funcționale descriu comportamentul observabil al sistemului în timp ce cerințele nefuncționale fixează pragurile de performanță, securitate și uzabilitate sub care soluția nu mai este considerată viabilă pentru scenariul de supraveghere vizat. Ambele au fost derivate plecând de la analiza stadiului actual (Capitolul 2) și de la limitările identificate în soluțiile comerciale existente.

4.1.1 Cerințe funcționale

Cerințele funcționale sunt prezentate sub formă de listă numerotată, fiecare identificator **F_x** fiind referit ulterior în capitolele de proiectare și implementare. Lista nu detaliază toate operațiile CRUD, ci organizează funcționalitățile pe domenii coerente.

F1 – Streaming live multi-cameră. Sistemul trebuie să accepte simultan mai multe surse video (incluzând camera locală a stației, de tip webcam USB prin `cv2.VideoCapture`, precum și camere IP adăugate dinamic prin URL de flux RTSP/HTTP/MJPEG) pentru a livra fluxurile procesate către clienții web în timp real, folosind canalul WebSocket dedicat. Fiecare cameră are un identificator logic unic (**CAM-01**, **CAM-02**, ...) și poate fi pornită, oprită sau adăugată/eliminată fără a opri restul sistemului.

- F2 – Recunoaștere facială cu autorizare pe zone.** Pentru fiecare cadru, sistemul detectează fețele prezente, calculează embedding-uri faciale și le compară cu indexul FAISS construit din baza de persoane înregistrate. Pe lângă identificarea propriu-zisă, sistemul verifică dacă persoana are dreptul de acces în zona asociată camerei curente, marcând vizual indivizii neautorizați. Pentru a îmbunătăți robustețea recunoașterii, o persoană poate avea înregistrate mai multe imagini faciale. În plus, ștergerea unui utilizator declanșează reconstrucția indexului FAISS, iar modificarea metadatelor (nume, departament, zone autorizate) duce la reîmprospătarea cache-urilor de autorizare.
- F2bis – Extracție de attribute demografice.** Pe lângă identificare, sistemul estimează attribute demografice ale fețelor detectate (vârstă, gen și emoție) folosite atât pentru statisticile agregate (F10), cât și pentru îmbogățirea metadatelor jurnalizate per detecție.
- F3 – Detecție și recunoaștere a plăcuțelor de înmatriculare.** Sistemul localizează plăcuțele de înmatriculare în cadrele video și extrage textul acestora prin OCR, cu stabilizarea citirii prin vot pe mai multe cadre. O plăcuță este considerată autorizată dacă numărul stabilizat este regăsit în baza de date de plăcuțe înregistrate.
- F4 – Detecție foc/fum cu confirmare temporală.** Sistemul detectează prezența focului și a fumului în cadre. Pentru a reduce numărul de fals pozitive provocate de surse legitime (lumini, reflexii, obiecte de culoare apropiată), o alarmă de incendiu se generează doar după confirmarea pe o fereastră temporală configurabilă, nu pe baza unui singur cadru.
- F5 – Detecție arme.** Sistemul identifică obiectele de tip armă și marchează cadrele și camerele afectate.
- F6 – Clasificare acțiuni umane.** Sistemul clasifică acțiunile observate în cadrele video în categorii relevante pentru supraveghere (activitate normală, luptă sau vandalism).
- F7 – Alarmare.** La declanșarea unei detecții critice (persoană necunoscută, persoană necunoscută sau neautorizată într-o zonă restricționată, foc/fum confirmat, armă, acțiune periculoasă, plăcuță de înmatriculare neautorizată), sistemul generează o alarmă persistentă în baza de date, afișată în interfața utilizator cu severitatea și contextul corespunzător. Pentru a preveni inundarea operatorului cu alarme identice, este aplicată o *deduplicare temporală* pe perechea (cameră, tip), cu un cooldown fix de 30 de secunde. Alarmerile au un ciclu de viață propriu: pot fi vizualizate individual, marcate ca rezolvate (păstrând evidența utilizatorului care a făcut rezolvarea) și actualizate în masă (*bulk-update*).
- F7bis – Configurarea la runtime a detectoarelor.** Fiecare modul AI (recunoaștere facială, demografie, plăcuțe, foc, arme, acțiuni umane) poate

fi activat sau dezactivat individual fără repornirea backend-ului, prin endpoint-uri dedicate de tip `toggle`. Acest lucru permite operatorului să ajusteze sarcina GPU în funcție de scenariu (ex. dezactivarea citire plăcuțe pe camere de interior).

- F8 – Gestiunea entităților (CRUD).** Sistemul asigură operații complete (creare, citire, actualizare și ștergere) pentru entitățile principale: persoane (organizate pe departamente, cu fotografii multiple și embedding-uri faciale), zone (care includ indicatorul `is_restricted`), camere (gestionate prin descoperire dinamică sau prin salvare persistentă în baza de date), plăcuțe de înmatriculare și utilizatori (cu roluri specifice). Actualizările aplicate persoanelor sau plăcuțelor se reflectă imediat și consistent în indexul FAISS, dar și în listele de autorizare. În plus, sistemul pune la dispoziție endpoint-uri dedicate pentru interogarea *istoricului accesărilor* (asociat unei persoane sau plăcuțe), precum și pentru schimbarea parolei contului curent.
- F9 – Jurnalizare și export.** Detectiile și alarmele sunt stocate în jurnale interogabile, prin intermediul tabelelor `detection_logs` și `alarms`. Aceste jurnale pot fi filtrate după interval de timp, cameră, tip de eveniment, status sau prin căutare după subiect. Pentru accesările persoanelor și ale vehiculelor există jurnale dedicate, `access_logs` și `vehicle_access_logs`. Jurnalurile de detecție pot fi exportate în format **CSV** pentru analiză externă, iar accesul vehiculelor este disponibil și prin endpoint-ul dedicat `/api/logs/vehicle`.
- F10 – Statistici și panou de activitate.** Sistemul agregă datele jurnalizate și pune la dispoziție rapoarte și grafice privind frecvența detecțiilor (`/api/logs/stats`, `/api/logs/timeseries`, `/api/logs/breakdown`), distribuția alarmelor pe camere și zone, demografia persoanelor identificate și alte metrice utile operatorilor. Pe pagina principală există un panou de *activitate recentă* actualizat în timp real prin WebSocket, care servește ca dashboard operațional.

Figura 4.1 sintetizează cele 10 cerințe funcționale sub forma unei diagrame use-case UML, plasând cei doi actori (Administrator, Operator) în raport cu funcționalitățile sistemului, grupate vizual pe domenii: detecție AI (F2–F6), interacțiune cu utilizatorul (F1, F7, F10) și administrare (F8, F9).




Figura 4.1: Diagrama use-case UML a sistemului de supraveghere inteligent, cu actorii Administrator și Operator în raport cu cele 10 cerințe funcționale, grupate pe domenii (detectie AI, interacțiune cu utilizatorul, administrare).

4.1.2 Cerințe non-funcționale

Cerințele nefuncționale stabilesc atributele de calitate sub care vor opera funcționalitățile sistemului. Acestea sunt marcate prin identificatori de forma **NF x** (paralel cu **F x** din §4.1.1), permițând referențierea lor în etapele ulterioare de proiectare, implementare și testare.

NF1 – Performanță (latență per cadru). Pipeline-ul principal de procesare a unui cadru, măsurat de la momentul achiziției până la difuzarea rezultatelor către clienți, trebuie să se încadreze sub **100 ms per cadru**, ceea ce permite atingerea unei rate de aproximativ **30 FPS** pe fluxul live al camerei principale. Această țintă este derivată din modul de operare paralel al firelor de execuție: fiecare detector rulează într-un fir dedicat, astfel încât latența percepută să fie dominată de cel mai lent detector de pe calea critică (recunoașterea facială), în timp ce detectorul cu cadență de clip (HAR/SlowFast, care procesează clipuri acumulate pe ~ 2 s) este suprapus asincron și nu se adună la latența per cadru.

NF2 – Scalabilitate. Arhitectura trebuie să permită extinderea la **mai multe camere simultan** fără modificări structurale ale codului, ci doar prin replicarea firelor de captură și ajustarea cozilor de cadre. Modelele AI sunt încărcate o singură dată în memorie și partajate între fluxuri, pentru a evita duplicarea costurilor de inițializare GPU.

NF3 – Securitate. Operațiile sensibile ale API-ului (precum gestiunea persoanelor, zonelor, plăcuțelor, utilizatorilor și configurarea modulelor AI) sunt protejate folosind o **autentificare bazată pe JWT** și restricționate printr-un **control de acces bazat pe roluri (RBAC)** cu nivelurile **admin** și **user**. Mai exact, acțiunile administrative sunt condiționate de dependența **require_admin**, regulă aplicată și endpoint-urilor de control al camerelor. Parolele sunt stocate în format hash (folosind bcrypt), iar token-urile au un timp de viață limitat la 8 ore. Cheia de semnare JWT este preluată din mediul de execuție prin variabila **JWT_SECRET**; în regim de producție (**APP_ENV=production**) absența sau lungimea insuficientă a acestei chei oprește explicit pornirea aplicației (*fail-fast*), fallback-ul cu o cheie aleatorie temporară fiind permis doar în dezvoltare. Sesiunile pot fi revocate instantaneu, înainte de expirarea celor 8 ore, printr-o **listă neagră** de token-uri (endpoint **/api/logout**). De asemenea, canalul WebSocket de streaming necesită autentificare. Token-ul JWT este transmis ca parametru de interogare (**/ws?token=...**) și este revalidat constant față de baza de date, prevenind astfel accesul unui cont suspendat sau șters la fluxul live. Comunicatia cu baza de date PostgreSQL se realizează prin credențiale dedicate, externalizate în variabile de mediu și izolate strict de datele utilizatorilor finali.

NF4 – Fiabilitate. Indexul FAISS este reconstruit deterministic din PostgreSQL la fiecare pornire, astfel încât pierderea fișierului de index nu duce la pierderea datelor faciale. Pipeline-ul tolerează căderea temporară a unei ca-

mere fără a opri procesarea celorlalte fluxuri. Cozile de cadre folosesc politici de tipul *drop-oldest* la saturare, astfel încât un detector lent să nu blocheze fluxul principal.

NF5 – Configurabilitate la runtime. Administratorul poate activa/dezactiva fiecare modul AI fără a necesita repornirea backend-ului și poate adăuga sau elimina dinamic camere IP. În ceea ce privește pragurile de confidență ale detectoarelor și ferestrele de *cooldown* pentru alarme și jurnale, acestea sunt definite ca parametri centralizați în cod. Deși pot fi ajustați fără a impune o reimplementare a logicii, acești parametri nu sunt expuși pentru modificare directă din interfața grafică.

NF6 – Mentenabilitate. Codul respectă o separare strictă pe module: fiecare detector (`facial_recognition_system`, `fire_detection_system`, `license_plate_recognition_system`, `weapon_detection_system`, `har_system`) este o unitate de sine stătătoare, importată de `app.py` și plasată într-un fir de execuție dedicat. Adăugarea unui nou detector se reduce la implementarea aceleiași interfețe și conectarea unui nou fir cu cozile sale.

NF7 – Observabilitate. Toate detecțiile și alarmele sunt înregistrate incluzând un timestamp, tipul evenimentului, camera, subiectul, nivelul de confidență, severitatea și metadatele JSON, oferind astfel un istoric complet și interogabil. La pornire, backend-ul raportează starea componentelor critice (resursele GPU/CUDA, modelele încărcate, conexiunea cu baza de date).

NF8 – Uzabilitate. Interfața de utilizare este dezvoltată sub forma unei aplicații web *responsive*, fiind accesibilă atât de pe stațiile de lucru fixe, cât și de pe dispozitive mobile pentru supravegherea de la distanță. Accesul în cadrul platformei este structurat pe roluri. Astfel, administratorul beneficiază de control complet asupra zonei de configurare și a gestiunii entităților, în timp ce operatorul utilizează interfața preponderent pentru vizualizarea fluxurilor video live și monitorizarea jurnalului de alarme.

NF9 – Portabilitate și mediu de execuție. Backend-ul este scris în Python (FastAPI), iar inferența AI necesită GPU compatibil CUDA pentru ca `InsightFace` și celelalte modele să atingă latențele țintă; în absența unui provider CUDA disponibil, `onnxruntime` revine automat pe `CPUExecutionProvider`, sistemul rămânând funcțional, dar cu latențe semnificativ mai mari. Frontend-ul este o aplicație React standard, distribuibilă ca artefact static.

4.2 Cazuri de utilizare

După formularea cerințelor în Secțiunea 4.1, pasul firesc este transpunerea acestora în interacțiuni concrete între actori și sistem. Această secțiune identifică

actorii, le delimitează responsabilitățile și descrie narativ cazurile principale de utilizare, oferind astfel puntea dintre *ce* oferă sistemul (cerințele $F\mathbf{x}$) și *cum* este folosit în practică.

Actori.

Sistemul distinge două roluri principale, mapate pe câmpul **role** al entității **user** din baza de date:

- **Administrator** – responsabil de configurarea sistemului. Are acces complet la gestiunea entităților (persoane, plăcuțe, zone, camere, utilizatori), la activarea/dezactivarea modulelor AI și activarea/dezactivarea camerelor de supraveghere. Tot ceea ce ține de *ce vede* sistemul și *pe cine îl recunoaște* este responsabilitatea acestui actor.
- **Utilizator obișnuit** – responsabil de supravegherea operațională. Vizualizează fluxurile live, monitorizează panoul de alarme, le triază și le marchează ca rezolvate și consultă jurnalele. Nu are dreptul să modifice configurația sistemului, să gestioneze entitățile sau să creeze conturi noi.

Ambii actori partajează un set comun de cazuri de utilizare (autentificare, schimbare parolă, vizualizare live și consultare jurnale), pe lângă care li se atribuie privilegii specifice fiecărui rol. Suplimentar, platforma interacționează cu o serie de *actori externi* pasivi, precum camerele IP, modelele AI și baza de date PostgreSQL. Deși nu reprezintă actori în sensul strict al modelării UML, aceste componente sunt esențiale și sunt tratate drept sisteme suport.

Cazuri de utilizare.

Cazurile sunt numerotate UC1...UC12 și descrise în formă narativă (pre-condiție, scenariu principal, post-condiție), cu trimitere la cerințele funcționale pe care le acoperă.

Figura 4.2 prezintă diagrama detaliată a cazurilor de utilizare. Cei doi actori (Administrator, Operator) sunt plasați la margini și conectați la elipsele cazurilor de utilizare. Cazurile UC1–UC3, UC10, UC11 și consultarea jurnalelor (UC12a) sunt partajate de ambii actori, în timp ce UC4–UC9 și vizualizarea statisticilor (UC12b) sunt accesibile doar Administratorului. Relațiile «include» marchează autentificarea (UC1) ca pre-condiție a tuturor celorlalte cazuri, iar relația «extend» leagă rezolvarea alarmei (UC11) de monitorizarea alarmelor (UC10).



- UC1 – Autentificare în sistem.** *Actori:* Administrator, Operator. *Pre-condiție:* utilizatorul are un cont creat. *Scenariu:* Utilizatorul introduce numele de utilizator și parola în pagina de login; backend-ul verifică hash-ul parolei, generează un token JWT semnat și îl returnează clientului, care îl stochează local și îl atașează tuturor cererilor ulterioare. *Post-condiție:* sesiunea este activă, iar UI-ul afișează doar componentele permise rolului utilizatorului. *Acoperă:* parte din NF3 (autentificare JWT).
- UC2 – Vizualizare fluxuri live multi-cameră.** *Actori:* Administrator, Operator. *Pre-condiție:* cel puțin o cameră este pornită. *Scenariu:* Utilizatorul deschide pagina principală; clientul stabilește o conexiune WebSocket cu backend-ul; backend-ul difuzează cadrele procesate (cu detecțiile suprapuse) către toți clienții conectați, la o rată țintă de aproximativ 30 FPS. Utilizatorul poate selecta camera afișată în prim-plan dintr-un grid. *Post-condiție:* fluxurile sunt afișate în timp real cu adnotările vizuale ale detectoarelor active. *Acoperă:* F1 (și indirect F2–F6 pentru adnotările suprapuse).
- UC3 – Schimbare parolă cont propriu.** *Actori:* Administrator, Operator. *Scenariu:* Utilizatorul autentificat introduce noua parolă; backend-ul o validează, o hash-uieste și o salvează în baza de date prin endpoint-ul `/api/users/me/password`. *Post-condiție:* la următoarea autentificare se folosește noua parolă. *Acoperă:* parte din NF3.
- UC4 – Înregistrare persoană nouă.** *Actor:* Administrator. *Scenariu:* Utilizând un singur formular, administratorul introduce metadatele persoanei (nume, `employee_id`, departament, zone autorizate) și încarcă una sau mai multe imagini faciale. La trimiterea datelor, interfața orchestrează transparent două apeluri REST succesive. Primul apel, `/api/persons/register`, stochează metadatele și returnează noul `person_id`. Al doilea apel, `/api/persons/{person_id}/faces`, declanșează la nivelul backend-ului extragerea embedding-ului InsightFace de 512 dimensiuni pentru fiecare imagine, salvarea acestuia în tabela `face_embeddings` și reconstrucția automată a indexului FAISS. *Excepție:* Dacă într-o imagine nu este detectată *exact* o singură față (situație care generează un embedding de tip `None`), imaginea respectivă este ignorată și semnalată în lista de erori, fără a bloca procesarea celorlalte fișiere. *Post-condiție:* Imediat după finalizarea procesului, persoana poate fi identificată în fluxurile video live. *Acoperă:* F2, F8.
- UC5 – Gestiune zone.** *Actor:* Administrator. *Scenariu:* Administratorul creează, actualizează sau șterge o zonă, stabilind numele, descrierea și indicatorul `is_restricted`. Drepturile de acces nu sunt configurate la nivelul zonei, ci la nivelul individului, prin intermediul listei `authorized_zones` asociate fiecărei persoane (conform UC4), zona fiind referențiată prin nume. Orice modificare aplicată se propagă imediat în logica de verificare a accesului, odată cu reîmprospătarea memoriei cache aferente. *Post-condiție:* Detectarea unei persoane necunoscute sau neautorizate într-o

zonă cu acces restricționat va declanșa automat o alarmă (conform UC10).
Acoperă: F2, F8 și parțial F7.

UC6 – Gestiune plăcuțe. *Actor:* Administrator. *Scenariu:* Administratorul adaugă, modifică sau șterge datele aferente unei plăcuțe de înmatriculare (precizând numărul, tipul vehiculului, numele și ID-ul proprietarului, indicatorul `is_authorized`, data de expirare și diverse note). Spre deosebire de profilurile persoanelor, plăcuțele nu presupun o autorizare la nivel de zonă. În schimb, un vehicul este considerat autorizat dacă numărul său de înmatriculare figurează în baza de date în momentul procesării OCR. *Post-condiție:* Plăcuțele identificate sunt comparate cu înregistrările existente și *jurnalizate* cu statusul `authorized` sau `unauthorized`. Suplimentar, o citire OCR validă pentru o plăcuță neautorizată declanșează automat o alarmă cu nivel de severitate `high` (conform UC10 și F7). *Acoperă:* F3, F7, F8, F9.

UC7 – Adăugare/eliminare cameră. *Actor:* Administrator. *Scenariu:* Administratorul adaugă o cameră IP nouă prin specificarea URL-ului de streaming, a unui identificator unic și a locației, având totodată opțiunea de a activa o cameră persistentă din configurația stocată în baza de date (`/api/cameras`). Imediat după inițiere, backend-ul accesează fluxul video, lansează firul de execuție pentru captură și adaugă dispozitivul în lista camerelor active. Operația inversă, de eliminare a unei camere, va opri firul de execuție și va elibera resursele alocate. *Post-condiție:* Camera devine vizibilă sau este retrasă automat din interfața de vizualizare de tip grid. *Acoperă:* F1, F8.

UC8 – Configurarea modulelor AI la runtime. *Actor:* Administrator. *Scenariu:* Administratorul accesează panoul *Intelligence Settings* și activează sau dezactivează în mod individual modulele (recunoașterea facială, analiza demografică, citirea plăcuțelor, detecția focului, a armelor și a acțiunilor umane) utilizând endpoint-urile de tip `toggle`. Modificarea are efect imediat, fără repornirea backend-ului. Firul de execuție corespunzător începe sau încetează să mai pună cadre în coadă. *Post-condiție:* pipeline-ul rulează cu noul set de detectoare active. *Acoperă:* F7bis, NF5.

UC9 – Gestiune utilizatori. *Actor:* Administrator. *Scenariu:* Administratorul creează un cont nou, specificând numele, parola inițială și rolul asociat. Ulterior, acesta poate să modifice nivelul de acces atribuit sau să elimine conturi existente. *Post-condiție:* setul de utilizatori autorizați să acceseze sistemul este actualizat. *Acoperă:* F8, NF3.

UC10 – Monitorizare alarme. *Actori:* Administrator, Operator. *Pre-condiție:* pipeline-ul de procesare rulează și are detectoare active. *Scenariu:* ori de câte ori se declanșează o detecție critică, backend-ul, după aplicarea cooldown-ului de deduplicare, salvează o alarmă în baza de date împreună cu o captură (snapshot). Clientul interoghează periodic endpoint-ul

/api/alarms și afișează alarmele în panoul de alarme, cu severitatea, camera, timestamp-ul și captura asociată. *Post-condiție*: alarma este vizibilă tuturor operatorilor. *Acoperă*: F7, F2–F6, NF1.

UC11 – Rezolvare alarmă. *Actor*: Operator (sau Administrator). *Pre-condiție*: Există cel puțin o alarmă activă în sistem. *Scenariu*: Operatorul selectează o alarmă din panoul dedicat și o marchează drept rezolvată. Backend-ul înregistrează identitatea utilizatorului care a acționat, alături de timestamp-ul aferent rezolvării. Această operațiune poate fi aplicată și în masă (*bulk-update*) pentru a gestiona simultan un grup de alarme. *Extinde*: UC10. *Post-condiție*: Alarma vizată trece în starea **resolved** și este eliminată din vizualizarea alertelor active. *Acoperă*: F7.

UC12 – Consultare jurnale și statistici. *Scenariu*: Procesul este împărțit în două direcții principale de acțiune. Pentru *consultarea jurnalelor* (*actori*: Administrator și Operator), utilizatorul accesează pagina dedicată și aplică filtre în funcție de intervalul de timp, cameră, tipul evenimentului, status și subiect. Backend-ul returnează rezultatele sub formă paginată, oferind totodată opțiunea de export în format CSV. Pentru *vizualizarea statisticilor* (*actor*: exclusiv Administrator), interfața afișează grafice agregate precum evoluția detecțiilor în timp, proporția fiecărui tip de eveniment și activitatea per cameră. *Post-condiție*: Utilizatorul obține o perspectivă de ansamblu detaliată asupra activității sistemului pentru perioada selectată. *Acoperă*: F9, F10.

Tabelul de trasabilitate cerință→caz de utilizare se regăsește implicit prin trimerile *Acoperă*: din fiecare descriere de mai sus și va fi folosit ca referință în Capitolul 7, unde fiecare caz de utilizare este verificat printr-un scenariu de test corespunzător.

4.3 Arhitectura generală a sistemului

După stabilirea cerințelor (§4.1) și a cazurilor de utilizare (§4.2), această secțiune prezintă arhitectura sistemului la nivel macro, evidențiind structura fundamentală, descompunerea în componente logice și distribuția acestora pe noduri fizice. Detaliile interne ale pipeline-ului multi-threaded și ale interfețelor REST/WebSocket sunt amânate pentru Secțiunile 4.4–4.6.

Sistemul este construit ca o aplicație web cu **trei straturi logice**: prezentare (clientul React), aplicație (backend-ul FastAPI cu pipeline-ul AI integrat) și persistență (baza de date PostgreSQL plus indexul FAISS reconstruit la pornire). Aceste straturi sunt utilizate de **cinci tipuri de actori tehnici**: utilizatorii umani prin browser, camerele video ca surse externe de date, modelele AI încărcate în memorie ca dependente în proces, baza de date ca sistem suport și GPU-ul ca resursă de calcul. Alegerea unei arhitecturi monolitice pentru backend, în care toate detectoarele rulează în același proces și partajează memoria GPU, este justificată în §4.4.3.




Figura 4.3: Diagramă bloc de ansamblu a sistemului, organizată pe cele trei straturi logice (Prezentare, Aplicație, Persistentă) și protocoalele de comunicare dintre componente: HTTPS/REST și WebSocket între client și backend, RTSP/HTTP/MJPEG pentru fluxurile camerelor, apeluri în proces către modelele AI de pe GPU și acces SQL la PostgreSQL prin driver-ul `psycopg2`. Indexul FAISS este menținut în memoria backend-ului și reconstruit din PostgreSQL la pornire.

4.3.1 Modelul client-server

Sistemul urmează un model client-server clasic, cu o singură instanță a serverului care deserveste simultan mai mulți clienți web. Conexiunile sunt asimetrice: pentru operațiile tranzacționale (login, CRUD pe entități, interogări de jurnale, preluarea alarmelor) se folosește un canal **REST sincron** peste HTTP/HTTPS, iar pentru transmiterea continuă a cadrelor video procesate se folosește un canal **WebSocket** peste TCP, în care fluxul de date este predominant unidirecțional (server→client).

4.3.1.1 Clientul

Frontend-ul este o aplicație **React 19** compilată cu Create React App și stilizată cu Tailwind, livrabilă ca artefact static. Este o aplicație de tip *single-page*, organizată pe ecrane comutate printr-o stare internă (`activeTab`), fără un router dedicat: `CameraGrid`, `PersonManagement`, `PlateManagement`, `ZoneManagement`, `CameraManagement`, `UserManagement`, `AlarmManagement`, `Logs`, `Statistics`, `IntelligenceSettings`, `RecentActivity`. Clientul nu execută niciun cod AI, rolul său este de a afișa cadrele primite prin WebSocket, de a colecta input-ul utilizatorului și de a-l transmite ca apeluri REST.

4.3.1.2 Serverul

Backend-ul este o aplicație **FastAPI** pornită pe portul 8000 din `app.py`, încărcat ca o singură instanță Uvicorn (fără reload, pentru a evita dubla inițializare a modelelor pe GPU). Endpoint-urile sunt protejate prin token JWT și verificări

de rol (dependențele `require_admin` / `get_current_user`), aplicate înainte de invocarea handler-ului: operațiile administrative (controlul camerelor, gestiunea entităților, comutatoarele AI) necesită rolul de administrator, iar endpoint-urile operaționale (starea sistemului, listarea camerelor, jurnale) necesită doar autentificare. Canalul WebSocket este, la rândul lui, autentificat prin token JWT transmis ca parametru de interogare (aspect detaliat în §4.8). Pe lângă deservirea cererilor HTTP, serverul găzduiește pipeline-ul AI ca un set de fire de execuție de fundal, descrise în §4.4.

4.3.1.3 Sursele video

Camerele video funcționează ca actori externi care nu inițiază niciodată conexiuni către server. Serverul este responsabil cu deschiderea fluxurilor video prin intermediul bibliotecii OpenCV. Aceste surse pot include camera locală a stației și camere IP integrate prin URL-uri de streaming (RTSP/HTTP/MJPEG). Eșecul unei camere, cum ar fi un *timeout* sau o deconectare neprevăzută, nu propagă o eroare în cascadă, ci doar marchează camera ca inactivă și permite repornirea ulterioară.

4.3.1.4 Persistența

Stratul de persistență combină **PostgreSQL** utilizat pentru stocarea permanentă cu un **index FAISS** menținut în memoria backend-ului pentru căutarea vectorială rapidă a embedding-urilor faciale 512-d. Indexul nu reprezintă mecanismul principal de stocare a datelor, ci este reconstruit determinist din PostgreSQL la fiecare pornire prin modulul `faiss_index.py`, astfel încât pierderea fișierului de cache nu afectează integritatea informațiilor.

4.3.2 Diagrama de componente

La nivel intern, backend-ul este descompus în următoarele componente logice. Fiecare componentă este un modul Python sau un grup de fire de execuție cu responsabilitate clară, cuplate prin cozi `queue.Queue` sau prin apeluri directe.

Modul de captură. Implementat în `app.py` sub forma unui fir de execuție per cameră activă, care deschide fluxul prin OpenCV, citește cadrele în mod sincron și le distribuie (prin clonare `frame.copy()`) în cozile de procesare ale fiecărui detector activ și în coada `raw_frame_queue` folosită ca fallback pentru fuziune.

Modul AI. Containerul pentru toate detectoarele specializate, încărcate o singură dată la pornire și partajate între fluxurile camerelor. Conține următoarele sub-module independente, fiecare cu propriul fir de execuție și propria pereche de cozi (`*_processing_queue` de intrare, `*_results_queue` de ieșire):

- `facial_recognition_system` – detecție de fețe (**InsightFace**), embedding-uri 512-d, căutare în FAISS, extragere attribute demografice (vârstă, gen prin InsightFace; emoție prin Mini-Xception/FER).
- `license_plate_recognition_system` – detecție și OCR pe plăcuțe (**YOLOv8** pentru localizare + **EasyOCR** pentru text).
- `fire_detection_system` – detector foc/fum cu **confirmare temporală** pe fereastră multi-cadru, pentru reducerea fals pozitivelor.
- `weapon_detection_system` – detector **YOLOv8m** fine-tuned pe clasa unică *weapon*, antrenat pe Zenodo *Dangerous Items* + Roboflow *SOHAS*.
- `har_system` – recunoaștere acțiuni umane folosind **SlowFast-R50**, care clasifică fiecare clip în acțiunile `normal`, `fight` și `vandalism`.

Modul de fuziune. Firul *result merger* colectează rezultatele parțiale din toate cozile de ieșire ale detectoarelor active, le asociază pe baza câmpului `frame_id` și produce un cadru final adnotat (cu bounding box-uri, etichete, scoruri de confidență), plus un set agregat de detecții. Tot aici se aplică **logica de declanșare a alarmelor** (verificarea zonelor restricționate, deduplicarea pe cooldown) și **politica de jurnalizare** (un singur log per (cameră, tip, subiect) într-o fereastră scurtă).

Modul de control al accesului. Cache-urile `_person_zones_cache` și `_camera_zone_cache` și logica asociată din `app.py` verifică, pentru fiecare *persoană* identificată, dacă aceasta are dreptul de acces în zona asociată camerei (comparând zona camerei cu lista `authorized_zones` a persoanei). Cache-urile sunt reîmprospătate periodic (TTL) și forțat la modificarea entităților relevante. Plăcuțele nu participă la acest mecanism, autorizarea lor fiind globală (§4.1.1).

API REST. Stratul de controlere FastAPI definit în `app.py`, organizat pe domenii: `/api/login`, `/api/persons`, `/api/plates`, `/api/zones`, `/api/cameras`, `/api/users`, `/api/logs`, `/api/alarms`, `/api/stats`, plus endpoint-urile `toggle` pentru fiecare modul AI. Fiecare controler validează token-ul JWT, aplică verificarea de rol și delegă efectiv către modulele de business sau către `database_manager.py`.

Gestiunea WebSocket. Endpoint-ul `/ws` autentifică clientul (token JWT ca parametru de interogare) și îi alocă o **coadă proprie** (`queue.Queue`), înregistrată în dicționarul `client_queues`; modulul de fuziune nu publică într-o coadă partajată, ci difuzează fiecare cadru procesat către coada fiecărui client prin metoda `_broadcast_frame` (politică *drop-oldest* per client, astfel încât un client lent să-și piardă doar propriile cadre vechi). Mesajele difuzate (câmpul `type: video_frame`) conțin cadrul codificat (JPEG la calitate 75, redimensionat la maxim 800 px lățime, Base64), rezultatele detectoarelor pe câmpuri separate (`face_results`, `plate_results`, etc.) și starea modulelor (flag-urile `*_enabled`). Comunicarea este *strict*

unidirecțională (server→client): handler-ul doar trimite cadre, fără a citi mesaje de la client. Alarmerle nu sunt transmise prin acest canal, ci preluate separat prin REST (§4.6).

Layer de persistență. Modulul `database_manager.py` centralizează toate accesele la PostgreSQL printr-o conexiune `psycopg2` persistentă (cu `RealDictCursor`), oferind operații CRUD și interogări parametrizate pentru toate entitățile. Indexul FAISS, deși tehnic în memoria procesului, este considerat parte a acestui layer pentru că este reconstruit din DB. Datele binare sunt păstrate tot în baza de date: embedding-urile faciale ca BYTEA în `face_embeddings`, iar capturile de alarmă (snapshot-urile) ca șiruri Base64 în coloana `snapshot` a tabelii `alarms`. Sistemul nu expune un serviciu de fișiere statice.

Cuplajul între componente este slab: fiecare detector poate fi activat/dezactivat independent (vezi UC8) fără a afecta restul, iar adăugarea unui nou detector se reduce la implementarea aceleiași interfețe (*intrare*: cadru, *ieșire*: listă de detecții) și conectarea unui nou fir cu cozile sale.




Figura 4.4: Diagrama de componente UML a backend-ului. Modulul Captură furnizează cadre (prin interfața *Cadru*) către Modulul AI. Acesta din urmă este o componentă complexă, alcătuită din cele cinci detectoare independente (recunoaștere facială, plăcuțe de înmatriculare, foc/fum, arme și acțiuni umane), care expune contractul comun *Detector* către Modulul Fuziune. Rolul Fuziunii este de a difuza cadrele adnotate către componenta de Gestiune WebSocket și de a salva alarmele și jurnalele generate. În paralel, API-ul REST realizează operațiile de tip CRUD. Ambele componente depind de Nivelul de Persistență, format din baza de date PostgreSQL și indexul FAISS (reconstruit la fiecare pornire). Contractele dintre componente sunt ilustrate vizual prin interfețe de tip lollipop.

4.3.3 Diagrama de implementare (deployment)

Distribuția fizică a sistemului este simplă în varianta de bază, constând într-un singur nod server pe care rulează toate componentele de procesare. Această arhitectură se poate extinde modular în cazul în care numărul de camere sau de clienți crește. Nodurile descrise mai jos sunt suficiente atât pentru scenariul demonstrativ al lucrării, cât și pentru un deployment de tip pilot.

4.3.3.1 Nodul client (browser)

Orice mașină cu un browser modern (Chrome, Firefox, Edge) care suportă WebSocket și ES2020. Nu există dependente instalate local: aplicația React este servită ca artefact static și se conectează la backend prin URL-ul configurat în `frontend/.env`. În scenariul de operare pot exista mai mulți clienți simultan.

4.3.3.2 Nodul server cu GPU

Mașina principală a sistemului, pe care rulează:

- procesul Python `app.py` (FastAPI + Uvicorn) cu toate firele AI;
- modelele AI încărcate în memoria GPU (InsightFace, YOLOv8, SlowFast, modelul de foc); modelul de emoție FER (Mini-Xception, TensorFlow) este ținut deliberat pe CPU, pentru a evita conflictele de runtime cu `onnxruntime-gpu`;
- indexul FAISS în memoria RAM;
- runtime-ul `onnxruntime-gpu` cu `CUDAExecutionProvider`, configurat la inițializarea InsightFace în `facial_recognition_system.py` (cu fallback pe `CPUExecutionProvider`).

Cerințele minime hardware sunt impuse de modelele AI: un GPU cu suport CUDA și cel puțin 8 GB VRAM pentru încărcarea simultană a tuturor detectoarelor; un CPU multi-core pentru cele ~7 fire de execuție; un SSD pentru log-uri și capturi.

4.3.3.3 Nodul bază de date

PostgreSQL poate coexista cu backend-ul pe același host (varianta implicită – conexiune prin `localhost`) sau poate fi externalizat pe un nod separat pentru scenarii de producție, accesat prin TCP cu credențiale dedicate.

4.3.3.4 Camere IP

Camerele sunt noduri independente, conectate la aceeași rețea locală cu serverul, care expun fluxuri RTSP, MJPEG sau HTTP. Identificarea lor este făcută prin URL plus un identificator logic (`CAM-01`, `CAM-02` etc.). Latența rețelei dintre camere și server contribuie direct la bugetul de 100 ms al cerinței NF1, motiv pentru care se recomandă rețea cablată sau Wi-Fi dedicat.




Figura 4.5: Diagrama de implementare (deployment) UML a sistemului. Nodul *Client (Browser)* – în una sau mai multe instanțe ($\{1..m\}$) – servește aplicația React ca artefact static și comunică cu serverul prin HTTP și WebSocket pe portul 8000. Nodul *Server GPU* găzduiește procesul `app.py` (FastAPI + Uvicorn, cu cele ~ 7 fire de execuție), modelele AI încărcate în VRAM (InsightFace, cele două instanțe YOLOv8 pentru plăcuțe și arme, SlowFast-R50 și modelul de foc/fum) prin `onnxruntime-gpu`, modelul de emoție FER ținut deliberat pe CPU, indexul FAISS în memoria RAM și baza de date **PostgreSQL** (acces prin TCP/SQL pe portul 5432, indexul FAISS fiind reconstruit din ea la pornire). *Camerele IP* (CAM-01..CAM-n, $\{1..n\}$) furnizează fluxuri RTSP/MJPEG/HTTP.

4.4 Proiectarea pipeline-ului multi-threaded

Pipeline-ul multi-threaded reprezintă decizia arhitecturală centrală a sistemului. Acesta definește modul în care backend-ul reușește să ruleze simultan cinci modele AI eterogene procesând fluxul aceleiași camere, cu scopul de a livra rezultatele agregate respectând limita de latență NF1. Această secțiune descrie structura firelor de execuție, detaliază mecanismele de sincronizare alese și argumentează de ce o execuție paralelă in-proces este preferabilă comparativ cu o execuție secvențială sau cu o arhitectură bazată pe microservicii.

Decizia de bază este: **un fir de execuție per responsabilitate, cozi thread-safe cu capacitate limitată ca mecanism de cuplare slabă, un singur proces care găzduiește toate modelele pe GPU**. Această alegere derivă din trei constrângeri: (i) modelele AI au timpi de inferență neomogeni, care se întind pe mai bine de un ordin de mărime – de la ~ 4 ms pentru detecția YOLO a plăcuțelor până la ~ 83 ms pentru recunoașterea facială cu analiză demografică (latențe măsurate, vezi Tabelul 4.1 din §4.4.3), (ii) inițializarea GPU a fiecărui model este costisitoare și trebuie făcută o singură dată, (iii) operatorul trebuie să poată activa/dezactiva dinamic detectoarele (cerința F7bis, NF5).




Figura 4.6: Diagrama de flux a pipeline-ului multi-threaded. Cele **șapte fire de execuție** sunt reprezentate ca dreptunghiuri, iar cele unsprezece cozi `queue.Queue(maxsize=10)` ca cilindri. Fluxul cadrelor pornește de sus, de la `CaptureThread` (care, prin `_dispatch_frame`, depune câte o copie `frame.copy()` în cozile de *intrare*), coboară prin cele cinci coloane paralele de fire AI – fiecare adnotat cu latența de inferență măsurată (Tabelul 4.1) – ale căror rezultate converg, prin cozile de *ieșire*, către `MergingThread`. Acesta aplică politica *ultimul cadru disponibil* (folosind `raw_frame_queue` ca *fallback*), declanșează alarmele și difuzează cadrul adnotat prin `_broadcast_frame` în cozile per-client `client_queues`, de unde este preluat de clienții WebSocket. Politica de saturare diferă în funcție de direcția cozii: *omitere* la intrare (cadrul nou este abandonat dacă firul detectorului are deja un backlog) și *drop-oldest* la ieșire (se scoate cel mai vechi rezultat pentru a-l insera pe cel nou).

4.4.1 Cele 7 fire de execuție

Backend-ul pornește, la inițializarea instanței `EnhancedSurveillanceSystem`, exact șapte fire de execuție daemon (vizibile în `app.py` prin numele `CaptureThread`, `FaceProcessingThread`, `PlateProcessingThread`, `FireProcessingThread`, `HARProcessingThread`, `WeaponProcessingThread`, `MergingThread`). Fiecare fir are o singură responsabilitate și interacționează cu restul exclusiv prin cozile partajate, evitând astfel sincronizarea prin variabile partajate la nivel fin.

4.4.1.1 Firul 1 – Captura video

Firul `CaptureThread` citește ciclic câte un cadru de la fiecare cameră activă prin `cv2.VideoCapture.read()`, cu reconectare automată a camerelor IP căzute. Fiecare cadru primește un `frame_id` monoton crescător și, sub rezerva unui mecanism de *frame-skip* (se procesează un cadru la fiecare `frame_skip`), este transmis metodei `_dispatch_frame`. Aceasta depune, pentru fiecare detector activ, o *copie* a cadrului (`frame.copy()`) în coada de procesare corespunzătoare (`face_processing_queue`, `plate_processing_queue`, `fire_processing_queue`, `har_processing_queue`, `weapon_processing_queue`) și, doar dacă toate cozile detectoarelor active au acceptat cadrul, o copie în `raw_frame_queue`, folosită de fuziune ca *fallback* pentru cadrele pentru care nu au sosit încă rezultatele detectoarelor.

4.4.1.2 Firul 2 – Recunoaștere facială și analiză demografică

Firul `FaceProcessingThread` consumă din `face_processing_queue`, rulează detecția fețelor cu `InsightFace`, calculează embedding-urile 512-d, le caută în indexul FAISS în memoria procesului și asociază fiecărei detecții vârsta, genul (din `InsightFace`) și emoția (din modelul `Mini-Xception/FER`). Toate aceste operații sunt încapsulate într-un singur fir pentru că au aceeași intrare (regiunea facială) și aceeași localitate de cache GPU; separarea recunoașterii faciale de demografie ar dubla detecția fețelor fără beneficiu real.

4.4.1.3 Firul 3 – Plăcuțe de înmatriculare

Firul `PlateProcessingThread` rulează detecția plăcuțelor cu `YOLOv8` specializat, urmată de OCR-ul `EasyOCR` pe fiecare regiune detectată. Combinația detector+OCR este menținută în același fir deoarece OCR-ul operează doar pe ROI-urile produse de detector, iar separarea ar introduce o coadă inutilă pentru ROI-uri.

4.4.1.4 Firul 4 – Foc și fum

Firul `FireProcessingThread` rulează modelul de detecție foc/fum și menține starea temporală necesară confirmării pe fereastră multi-cadru (cerința F4). O detecție singulară nu produce alarmă. Doar o detecție confirmată pe câteva

cadre consecutive declanșează câmpul **alert** pe rezultatul publicat. Această stare este intern firului și nu necesită sincronizare.

4.4.1.5 Firul 5 – Recunoaștere acțiuni umane

Firul `HARProcessingThread` are un regim de funcționare distinct: acumulează cadre într-un buffer intern și, când are clipul complet de 64 cadre la `clip_duration_sec=2.0`, rulează `SlowFast-R50` cu pathway-urile `slow` (8 cadre) și `fast` (32 cadre) la `crop_size=224`, clasificând clipul în `normal`, `fight` sau `vandalism`. Forward-pass-ul `SlowFast` nu este cel mai scump dintre detectoare – măsurat, el costă în mediană ~ 8 ms pe GPU (Tabelul 4.1), mult sub recunoașterea facială. Particularitatea acestui fir este *cadența*, nu costul brut: el produce un rezultat o singură dată la ~ 2 s, pe măsură ce se umple clipul de 64 de cadre. Motivul principal pentru izolarea acestui modul nu este riscul de a bloca resursa GPU, ci necesitatea de a preveni ca ritmul său de acumulare a cadrelor să dicteze rata de actualizare a celorlalte detectoare din pipeline.

4.4.1.6 Firul 6 – Arme

Firul `WeaponProcessingThread` rulează modelul `YOLOv8m` fine-tuned pe clasa unică `weapon`. Detecția de armă este fără stare — fiecare cadru produce un rezultat independent printr-un singur forward-pass, fără buffer temporal (ca HAR) și fără procesare în aval pe ROI-uri (ca OCR-ul plăcuțelor). Tocmai această independență între cadre justifică firul dedicat: detecția poate rula la rata maximă a camerei, izolată de latența celorlalte detectoare — esențial pentru o clasă critică pentru siguranță.

4.4.1.7 Firul 7 – Fuziune

Firul `MergingThread` este nucleul de agregare: consumă neblockant din toate cozile de rezultate (`face_results_queue`, `plate_results_queue`, `fire_results_queue`, `har_results_queue`, `weapon_results_queue`) plus din `raw_frame_queue`, asociază rezultatele după `frame_id` și produce mesajul final pentru clienți (cadru adnotat + listă de detecții + alarme noi). Tot aici se aplică logica de declanșare a alarmelor (verificarea zonelor restricționate via `_person_zones_cache`, deduplicarea pe baza dicționarului `alarm_cooldowns` cu un cooldown de 30 s, jurnalizarea cu deduplicare pe `log_cooldowns` de 5 s). Mesajul final este difuzat prin metoda `_broadcast_frame`, care îl depune în coada proprie a fiecărui client `WebSocket` conectat (dicționarul `client_queues`), fără a trece printr-o coadă de ieșire partajată.

4.4.1.8 Justificarea separării

Alocarea pe fire respectă două principii: **omogenitatea computațională** (operații care partajează intrarea și cache-ul GPU stau împreună – ex. recunoaștere facială cu demografie, detecție plăcuță cu OCR) și **izolarea costului și a**

cadenței (firul cel mai costisitor pe cadru – recunoașterea facială cu demografie, ~ 83 ms – și firul cu cadență de clip – HAR – rămân separate, ca să nu impună latența, respectiv ritmul lor, celorlalte detectoare). Numărul 7 nu este un obiectiv în sine, ci o consecință a celor cinci familii de detecții cerute plus capătul de pipeline (captură) și nucleul de agregare (fuziune).

4.4.2 Mecanisme de sincronizare

Sincronizarea este realizată prin **cozi thread-safe cu capacitate limitată** ca mecanism principal și prin **lock-uri fine de tip threading.Lock** pentru structurile de stare partajată (cache de zone, dicționare de cooldown, lista de camere). Această împărțire reduce semnificativ riscul de *deadlock* și de *race condition*, pentru că majoritatea fluxului de date trece prin cozi, unde sincronizarea este implementată odată în standard library.

4.4.2.1 Cozi thread-safe

Toate cele unsprezece cozi folosite de pipeline sunt `queue.Queue(maxsize=10)` – cozi FIFO cu blocaj intern și suport nativ pentru apeluri ne-blocante (`block=False`) și pentru așteptare cu termen-limită (de exemplu `get(timeout=0.1)`). Capacitatea limitată la 10 este o decizie explicită: un buffer scurt înseamnă latență mică (cadrul cel mai vechi în pipeline este de cel mult 10 cadre vechi), dar înseamnă și că saturarea trebuie tratată. Politica de saturare diferă în funcție de direcția cozii, dar urmărește același scop – a nu lăsa coada să crească: la **intrare** (cozile de procesare `*_processing_queue` și `raw_frame_queue`, alimentate de `CaptureThread` prin `_dispatch_frame`), când coada unui detector (`*_processing_queue`) este plină, cadrul nou este pur și simplu *omis* (incrementând contorul `queue_skips`), pentru că detectorul respectiv încă procesează un backlog și nu are rost să-l adâncim; coada `raw_frame_queue` este alimentată doar dacă toate cozile detectoarelor au acceptat cadrul, iar în caz contrar – sau dacă ea însăși este plină – cadrul este numărat separat în contorul `frames_dropped`; la **ieșire** (cozile `*_results_queue` și cozile per-client WebSocket), producătorul aplică **drop-oldest** – scoate explicit elementul cel mai vechi cu `get(block=False)` și inserează noul rezultat. În ambele cazuri principiul este același: *contează cel mai recent cadru/rezultat, nu acumularea unei coade întregi de date vechi*.

4.4.2.2 Partajarea cadrului curent

Cadrela citite de `CaptureThread` sunt *clonate* (`frame.copy()`) înainte de a fi distribuite în cozile detectoarelor. Această decizie elimină complet sincronizarea pe conținutul cadrului: fiecare fir AI lucrează pe propria copie, prevenind astfel riscul modificării concurente a matricei de pixeli de către un alt fir de execuție. Costul memoriei este absorbit de capacitatea limitată a cozilor (cel mult $11 \times 10 = 110$ cadre simultan în RAM, în jur de 200 MB pentru rezoluții HD), iar costul copierii este sub 1 ms, neglijabil față de bugetul NF1.

4.4.2.3 Mecanismul *ultimul cadru disponibil*

Firul de fuziune nu așteaptă să aibă rezultatele *tuturor* detectoarelor pentru fiecare `frame_id`. Așteptarea ar reduce throughput-ul la minimum dintre detectoare (HAR, care livrează rezultate o dată la ~ 2 s, ar limita restul la 0.5 FPS). În schimb, fuziunea aplică o politică de tip *ultimul cadru disponibil*: consumă neblocaant din toate cozile de rezultate, păstrează în structuri locale ultimele rezultate per cameră primite de la fiecare detector și le suprapune pe cadrul cel mai recent. Astfel, detecțiile cu cadență continuă, produse pentru fiecare cadru (fețe, plăcuțe, foc, armă), sunt afișate la rata camerei, iar detecția cu cadență de clip (HAR), care livrează un rezultat o dată la ~ 2 s, este suprapusă cu valoarea ei cea mai recentă până la următoarea actualizare. Acest mecanism este cel care permite respectarea cerinței NF1 de 30 FPS *indiferent* de detectorul cel mai lent activ.

4.4.2.4 Stare partajată protejată prin lock-uri

Câteva structuri trebuie totuși accesate concurent: lista camerelor active (`cameras_lock`), dicționarele de cooldown pentru alarme și jurnale (`alarm_lock`, `log_lock`), cache-urile de autorizare pe zone (`_zone_cache_lock`) și dicționarul cozilor per-client WebSocket (`client_lock`). Pentru toate acestea se folosesc lock-uri de tip `threading.Lock`, cu scope foarte restrâns (câteva linii înăuntrul blocului `with self.X_lock:`), pentru a minimiza timpul în care un fir este blocat.

4.4.3 Justificarea procesării paralele

Alternativa naturală la pipeline-ul paralel este **procesarea secvențială** – pentru fiecare cadru, se aplică pe rând detector 1, detector 2, ..., detector 5, apoi se trimite rezultatul la client. Această variantă a fost respinsă din mai multe motive concrete, măsurabile pe propriul cod.

4.4.3.1 Utilizarea GPU-ului

Modelele AI partajează aceeași memorie GPU, dar nu același tip de calcul: InsightFace face inferență single-shot pe regiuni mici, YOLO face inferență pe imagine întreagă, SlowFast face inferență pe clip 3D temporal. Rularea lor în fire separate permite suprapunerea **copierii host→device** a unui detector cu **kernel execution** a altuia, prin streams CUDA, ceea ce într-o execuție secvențială ar rămâne timp mort. În plus, ONNX Runtime și PyTorch folosesc thread pool-uri interne care exploatează concurența la nivel de operator – iar acestea sunt active doar dacă apelurile vin din fire diferite.

4.4.3.2 Măsurarea latențelor de inferență

Cifrele de latență folosite în această secțiune și în Figura 4.6 nu sunt estimări, ci valori **măsurate** pe sistemul real. Pentru aceasta a fost rulat un script de

benchmark dedicat (`benchmark_inference.py`), care încarcă fiecare detector exact ca în `app.py` și îi cronometrează metoda `process_frame` pe un clip video reprezentativ – o filmare în care apar mai multe persoane (deci mai multe fețe simultan) și, ocazional, autovehicule cu plăcuțe de înmatriculare vizibile.

Metodologia urmărește izolarea timpului *de inferență* de costurile de pornire. Pentru fiecare detector se rulează întâi 10 cadre de încălzire (prima inferență pe GPU este sistematic mai lentă, din cauza alocării de memorie și a compilării kernel-urilor CUDA), apoi se măsoară 200 de cadre cu `time.perf_counter()`, forțând sincronizarea GPU (`torch.cuda.synchronize()`) înainte de oprirea cronometrului, astfel încât să se contorizeze execuția efectivă a kernel-urilor, nu doar lansarea lor asincronă. Se raportează mediana și percentila 95, mai robuste decât media în prezența cozilor lungi de latență. Inițializarea modelelor (încărcarea pe GPU) nu este inclusă în măsurători.

Măsurătorile au fost efectuate pe o stație cu **GPU NVIDIA GeForce RTX 4060 Laptop**, **CPU Intel Core Ultra 9 185H** și 30 GB RAM. Toate modelele rulează pe GPU, cu o singură excepție notabilă: clasificatorul de emoții (Mini-Xception/FER) rulează **pe CPU**, deoarece este suficient de mic încât latența să rămână acceptabilă, iar GPU-ul rămâne dedicat modelelor grele (vezi §5.2.4). Rezultatele sunt sintetizate în Tabelul 4.1.

Tabel 4.1: Latente de inferență măsurate per detector, pe un clip video reprezentativ (200 de cadre măsurate per modul, după 10 cadre de încălzire). Hardware: GPU NVIDIA GeForce RTX 4060 Laptop, CPU Intel Core Ultra 9 185H.

Detector	Mediană (ms)	p95 (ms)	Debit (cadre/s)
Plăcuțe (YOLOv8 + EasyOCR)*	4.0	4.7	249
Foc/fum	24.6	25.6	41
Armă (YOLOv8m)	13.1	13.5	76
Acțiuni umane HAR (SlowFast-R50)	8.1	17.3	124
Recunoaștere facială (InsightFace + FAISS + FER)	83.4	161.4	12

* Mediana modului de plăcuțe este dominată de cadrele fără plăcuță, în care rulează doar detecția YOLO; când EasyOCR se declanșează pe o plăcuță prezentă, latența crește la ~40–125 ms (vizibil în valorile maxime).

Trei precizări sunt necesare pentru interpretarea corectă a cifrelor. În primul rând, fiecare detector a fost măsurat *izolat*; în pipeline-ul real, cele cinci modele rulează concurrent pe aceeași placă, astfel încât latențele sub sarcină completă, cu competiție pentru resursele GPU, sunt mai mari decât valorile per-modul din tabel – care reprezintă deci un *plafon* optimist. În al doilea rând, mediana de ~4 ms a modului de plăcuțe reflectă majoritatea cadrelor în care *nu* apare nicio plăcuță (rulează doar detecția YOLO); comportamentul real este dependent de date, latența urcând la ~40–125 ms atunci când OCR-ul se aplică efectiv pe o plăcuță. În al treilea rând, cifrele sunt specifice hardware-ului folosit; pe un alt GPU ele s-ar modifica proporțional, motiv pentru care configurația de test este raportată explicit.

4.4.3.3 Latența percepută per modul

Într-un pipeline secvențial, latența percepută de utilizator pentru *orice* detector este suma timpilor de inferență ai *tuturor* detectoarelor active. Cu latențele măsurate (Tabelul 4.1), suma medianelor celor cinci detectoare este de ~ 133 ms ($4 + 25 + 13 + 8 + 83$ ms), iar doar recunoașterea facială costă ~ 83 ms. Astfel, chiar și un client interesat exclusiv de fețe ar primi rezultate abia după ce *toate* detectoarele active au terminat, adică la ~ 133 ms după captură. Aceasta ar reduce rata de afișare la ~ 7 – 8 cadre/s, sub pragul NF1 de 30 FPS, și ar depăși bugetul de latență de 100 ms. În pipeline-ul paralel, fiecare modul își are propria latență individuală (de la ~ 4 ms la ~ 83 ms), iar mecanismul *ultimul cadru disponibil* face ca afișarea să fie limitată de rata camerei, nu de suma detectoarelor.

4.4.3.4 Dezactivarea selectivă

Cerința F7bis cere posibilitatea activării/dezactivării individuale a detectoarelor la runtime. Într-un pipeline secvențial, dezactivarea unui modul ar însemna fie un if-else în corpul ciclului principal (cod fragil, cu test la fiecare cadru), fie o reconfigurare a lanțului de procesare. În arhitectura paralelă, dezactivarea înseamnă pur și simplu **a nu mai depune cadre** în coada detectorului respectiv – firul rămâne pornit, blocat pe `get()`, fără cost CPU. Reactivarea este simetrică și instantanee.

4.4.3.5 Tolerare la eșec

Dacă un detector se confruntă cu o eroare recuperabilă (excepție tratată la nivel local sau model temporar indisponibil), pipeline-ul paralel funcționează independent de acesta. Firul de execuție corespunzător consumă în continuare cadrele din buffer și înregistrează eroarea, iar etapa de fuziune gestionează lipsa datelor în mod transparent. Într-un flux secvențial, orice excepție ar trebui interceptată individual, iar penalizarea de performanță generată de blocurile `try/except` s-ar propaga asupra latenței întregului sistem.

4.4.3.6 De ce nu microservicii separate

O variantă și mai distribuită ar fi un detector per proces (sau per container), cu IPC între ele. Această opțiune a fost respinsă pentru că ar fi multiplicat costul de inițializare GPU (fiecare proces și-ar fi încărcat propriile modele, depășind rapid memoria VRAM disponibilă), ar fi introdus latență suplimentară prin serializare/deserializare cadrelor și ar fi complicat semnificativ deployment-ul (cerința NF9 de portabilitate). Multi-threading în-proces oferă paralelismul logic dorit cu cost zero la nivel de date partajate – toate firele văd aceeași memorie GPU și aceleași structuri de cache, ceea ce este exact ce trebuie pentru un singur server cu GPU dedicat (vezi §4.3.3).

4.5 Proiectarea API-ului REST

Toate operațiile tranzacționale ale sistemului (precum autentificarea, operațiile de tip CRUD asupra entităților, interogarea jurnalelor și a statisticilor, alături de controlul modulelor AI) sunt expuse prin intermediul unui API REST. Acesta este dezvoltat utilizând framework-ul FastAPI și este montat sub prefixul comun `/api`. Acest canal de comunicare este complementar protocolului WebSocket (detaliat în §4.6). Mai exact, API-ul REST deservește cereri punctuale, sincrone, bazate pe paradigma cerere-răspuns, în timp ce conexiunea WebSocket este dedicată transmiterii fluxului continuu de cadre video și alerte. Prezenta secțiune detaliază endpoint-urile disponibile (grupate pe categorii de funcționalități), convențiile de denumire adoptate, formatul standardizat al răspunsurilor și codurile HTTP de eroare utilizate.

4.5.1 Convenții de denumire

API-ul respectă consecvent convențiile REST: substantive la plural pentru colecții (`/api/persons`, `/api/zones`, `/api/plates`, `/api/cameras`, `/api/streams`, `/api/users`), identificatorul resursei ca segment de cale (`/api/persons/{person_id}`), iar verbul HTTP exprimă acțiunea (GET pentru citire, POST pentru creare, PUT pentru actualizare completă, PATCH pentru actualizare parțială, DELETE pentru ștergere). Sub-resursele și acțiunile derivate sunt exprimate ca segmente suplimentare (`/api/persons/{person_id}/faces`, `/api/persons/{person_id}/access-history`).

Cele două aspecte legate de camere sunt modelate ca resurse distincte, ambele denumite la plural. Fluxurile video procesate în timp real sunt expuse ca resursa `/api/streams`: un POST pornește un flux, un GET le listează pe cele active, iar un DELETE oprește un flux individual sau toate fluxurile. Configurațiile de camere persistate în baza de date sunt expuse separat, ca resursa `/api/cameras`. În același spirit, statisticile agregate folosesc consecvent sufixul `stats` – `/api/stats` la nivel de sistem, respectiv `/api/alarms/stats`, `/api/logs/stats`, `/api/har/stats` și `/api/weapon/stats` la nivel de modul – iar alarmele sunt grupate sub `/api/alarms`.

4.5.2 Catalogul endpoint-urilor pe categorii

Autentificare.

- POST `/api/login` – autentifică un utilizator (nume + parolă) și returnează un token JWT plus datele de profil.
- POST `/api/logout` – revocă token-ul curent (logout efectiv): `jti`-ul acestuia este înscris în lista neagră `revoked_tokens`, devenind invalid imediat, înainte de expirarea naturală.

Stare și control fluxuri video (runtime).

- GET /api/status – starea curentă a sistemului: streaming activ per cameră, ce module AI sunt pornite, statistici de performanță.
- POST /api/streams – pornește un flux video; corpul cererii selectează sursa: "local" pentru camera laptopului (id-ul rezervat CAM-01) sau "ip" împreună cu URL-ul, id-ul și locația unei camere IP.
- GET /api/streams – listează fluxurile active (camera locală + camerele IP).
- DELETE /api/streams/{camera_id} – oprește un flux individual; DELETE /api/streams – oprește toate fluxurile.

Control module AI (toggle).

- POST /api/face/toggle, /api/plate/toggle, /api/demographics/toggle, /api/fire/toggle, /api/har/toggle, /api/weapon/toggle – activează/dezactivează individual fiecare detector (cerința F7bis).
- GET /api/har/stats, GET /api/weapon/stats – statistici interne ale celor două detectoare.

Persoane.

- POST /api/persons/register – creează fișa unei persoane noi (metadata) și returnează person_id-ul.
- GET /api/persons – listează persoanele; GET /api/persons/departments – departamentele distincte.
- GET | PUT | DELETE /api/persons/{person_id} – citire/actualizare/ștergere a unei persoane.
- POST /api/persons/{person_id}/faces – încarcă imagini faciale pentru persoană (atât la înregistrare, cât și ulterior).
- GET /api/persons/{person_id}/access-history – istoricul accesărilor persoanei.

Plăcuțe de înmatriculare.

- POST /api/plates/register; GET /api/plates; GET /api/plates/vehicle-types.
- GET | PUT | DELETE /api/plates/{plate_number}; GET /api/plates/{plate_number} /access-history.

Zone.

- GET /api/zones; POST /api/zones; PUT | DELETE /api/zones/{zone_id}.

Camere (persistate în baza de date).

- GET /api/cameras; POST /api/cameras; PUT | DELETE /api/cameras/{camera_id}.

Alarmer.

- GET /api/alarms; GET /api/alarms/stats; GET /api/alarms/{alarm_id}.
- PATCH /api/alarms/{alarm_id} – marchează o alarmă (ex. rezolvată);
POST /api/alarms/bulk-update – actualizare în masă.

Jurnale.

- GET /api/logs – jurnalul de detecții, cu filtre; GET /api/logs/vehicle – jurnalul vehiculelor.
- GET /api/logs/stats, /api/logs/timeseries, /api/logs/breakdown – agregări pentru grafice.
- GET /api/logs/export – export CSV al jurnalului filtrat.

Statistic.

- GET /api/stats – metrice agregate la nivel de sistem.

Utilizatori.

- GET /api/users; POST /api/users; PUT | DELETE /api/users/{user_id}.
- PUT /api/users/me/password – schimbarea parolei contului propriu.

Tabelul 4.2 sintetizează catalogul complet, indicând pentru fiecare endpoint metoda HTTP, calea, rolul minim necesar – **Public** (fără autentificare), **Autentificat** (orice utilizator cu token JWT valid) sau **Admin** (rol privilegiat) – și cerința funcțională **Fx** pe care o deservește. Distincția de rol este impusă la nivel de backend prin dependențele FastAPI `get_current_user` (autentificare) și `require_admin` (autorizare de tip administrator).

Tabel 4.2: Catalogul endpoint-urilor REST: metodă HTTP, cale, rol minim necesar și cerința funcțională acoperită.

Metodă	Cale	Rol minim	Cerință
Autentificare			
POST	/api/login	Public	–

continuă pe pagina următoare...

... continuare a Tabelului 4.2

Metodă	Cale	Rol minim	Cerință
POST	/api/logout	Autentificat	-
Stare și control fluxuri video (runtime)			
GET	/api/status	Autentificat	F1
POST	/api/streams	Admin	F1
GET	/api/streams	Autentificat	F1
DELETE	/api/streams/{camera_id}	Admin	F1
DELETE	/api/streams	Admin	F1
Control module AI (toggle)			
POST	/api/face/toggle	Admin	F7bis
POST	/api/plate/toggle	Admin	F7bis
POST	/api/demographics/toggle	Admin	F7bis
POST	/api/fire/toggle	Admin	F7bis
POST	/api/har/toggle	Admin	F7bis
POST	/api/weapon/toggle	Admin	F7bis
GET	/api/har/stats	Autentificat	F6
GET	/api/weapon/stats	Autentificat	F5
Persoane			
POST	/api/persons/register	Admin	F8
GET	/api/persons	Admin	F8
GET	/api/persons/departments	Admin	F8
GET	/api/persons/{person_id}	Admin	F8
PUT	/api/persons/{person_id}	Admin	F8
DELETE	/api/persons/{person_id}	Admin	F8
POST	/api/persons/{person_id}/faces	Admin	F2
GET	/api/persons/{person_id}/access-history	Admin	F9
Plăcuțe de înmatriculare			
POST	/api/plates/register	Admin	F8
GET	/api/plates	Admin	F8
GET	/api/plates/vehicle-types	Admin	F8
GET	/api/plates/{plate_number}	Admin	F8
PUT	/api/plates/{plate_number}	Admin	F8
DELETE	/api/plates/{plate_number}	Admin	F8
GET	/api/plates/{plate_number}/access-history	Admin	F9
Zone			
GET	/api/zones	Autentificat	F8
POST	/api/zones	Admin	F8
PUT	/api/zones/{zone_id}	Admin	F8
DELETE	/api/zones/{zone_id}	Admin	F8
Camere (persistate în baza de date)			
GET	/api/cameras	Autentificat	F8
POST	/api/cameras	Admin	F8
PUT	/api/cameras/{camera_id}	Admin	F8
DELETE	/api/cameras/{camera_id}	Admin	F8
Alarme			
GET	/api/alarms	Autentificat	F7
GET	/api/alarms/stats	Autentificat	F7, F10
GET	/api/alarms/{alarm_id}	Autentificat	F7
PATCH	/api/alarms/{alarm_id}	Autentificat	F7
POST	/api/alarms/bulk-update	Autentificat	F7
Jurnale			
GET	/api/logs	Autentificat	F9
GET	/api/logs/vehicle	Autentificat	F9
GET	/api/logs/stats	Autentificat	F10
GET	/api/logs/timeseries	Autentificat	F10
GET	/api/logs/breakdown	Autentificat	F10

continuă pe pagina următoare...

... continuare a Tabelului 4.2

Metodă	Cale	Rol minim	Cerință
GET	/api/logs/export	Autentificat	F9
Statistici			
GET	/api/stats	Autentificat	F10
Utilizatori			
GET	/api/users	Admin	F8
POST	/api/users	Admin	F8
PUT	/api/users/{user_id}	Admin	F8
DELETE	/api/users/{user_id}	Admin	F8
PUT	/api/users/me/password	Autentificat	F8

4.5.3 Structura răspunsurilor

Răspunsurile sunt codificate JSON. Pentru operațiile de comandă (POST, PUT, PATCH, DELETE), *payload*-ul utilizează o structură standardizată, compusă dintr-un câmp `status` (cu valorile "success", "info" sau "error"), însoțit de un câmp `message` explicativ:

```
{ "status": "success", "message": "Camera started" }
```

Răspunsul de autentificare adaugă token-ul și profilul utilizatorului:

```
{ "status": "success",
  "token": "<JWT>",
  "user": { "id": 1, "username": "admin",
            "role": "admin", "full_name": "..." } }
```

Pentru operațiile de citire (GET), răspunsul constă fie direct în obiectul sau colecția solicitată, fie în aceeași structură standardizată a *payload*-ului, care integrează datele cerute. Un detaliu relevant de implementare este faptul că toate răspunsurile sunt procesate prin intermediul funcției `convert_to_serializable`. Aceasta convertește tipurile de date NumPy (`np.integer`, `np.floating`, `np.ndarray`), des întâlnite în ieșirile modelelor AI, în tipuri native Python compatibile cu formatul JSON, prevenind astfel erorile de serializare.

4.5.4 Coduri de eroare

API-ul folosește codurile de stare HTTP standard, ridicate prin `HTTPException` din FastAPI:

- **200 OK** – succesul operației (implicit în FastAPI).
- **401 Unauthorized** – credentiale invalide la login ("Invalid username or password"), token expirat ("Token has expired") sau token invalid ("Invalid token").
- **403 Forbidden** – utilizator autentificat dar fără rolul necesar; ridicat de dependența `require_admin` cu mesajul "Admin access required" (vezi §4.8).

- **404 Not Found** – resursă inexistentă (persoană, plăcuță, zonă, alarmă cu ID inexistent).
- **422 Unprocessable Entity** – generat automat de FastAPI/Pydantic la validarea corpului cererii (câmpuri lipsă sau de tip greșit, conform modelelor `LoginRequest`, `BulkUpdateAlarmsRequest` etc.).
- **500 Internal Server Error** – excepții neașteptate (ex. eșecul deschiderii unei camere), capturate în handler și raportate cu `detail=str(e)`.

Corpul unei erori urmează formatul standard FastAPI, `{"detail": "<mesaj>"}`, ceea ce permite frontend-ului să afișeze direct mesajul în interfață.

4.6 Proiectarea canalului WebSocket

Dacă API-ul REST (§4.5) servește cereri punctuale, canalul WebSocket este responsabil de fluxul continuu de date în timp real: cadrele video procesate, adnotate cu rezultatele detectoarelor, sunt împinse de la server către toți clienții conectați. Această secțiune descrie endpoint-ul dedicat, formatul mesajelor (verificat direct în implementarea din `app.py`), cadența de transmitere și modul în care sunt tratate deconectarea și reconectarea.

4.6.1 Endpoint dedicat pentru streaming

Există un singur endpoint WebSocket, montat la `/ws`. La conectare, serverul autentifică mai întâi clientul – token-ul JWT este transmis ca parametru de interogare (`/ws?token=...`, deoarece browserele nu pot seta antete pe un WebSocket), este decodat și re-verificat față de baza de date, iar conexiunea este refuzată (cod de închidere 1008) dacă token-ul lipsește, este invalid/expirat sau aparține unui cont șters. Doar după validare serverul acceptă handshake-ul (`await websocket.accept()`) și alocă fiecărui client o **coadă proprie** (`queue.Queue`), înregistrată în dicționarul `client_queues`. Modelul este **broadcast unu-la-mulți**: firul de fuziune (§4.4.1) nu publică într-o coadă partajată, ci difuzează fiecare cadru, prin metoda `_broadcast_frame`, în coada fiecărui client; bucla fiecărui client consumă din coada sa și trimite mesajul mai departe. Comunicarea este predominant unidirecțională, server→client; clientul nu trebuie să trimită nimic pentru a primi fluxul.

4.6.2 Formatul mesajelor

Fiecare mesaj este un obiect JSON serializat cu `json.dumps` și trimis prin `send_text`. Mesajul de tip cadru video are următoarea structură (construită în metoda `_encode_and_queue_frame`):

```
{
  "type": "video_frame",
  "camera_id": "CAM-01",
  "frame": "<JPEG codificat Base64>",
  "face_results": [ ... ],
  "plate_results": [ ... ],
  "fire_results": [ ... ],
  "har_results": [ ... ],
  "weapon_results": [ ... ],
  "timestamp": "2026-05-20T12:34:56.789",
  "demographics_enabled": true,
  "fire_detection_enabled": true,
  "har_enabled": true,
  "weapon_detection_enabled": true
}
```

Câmpul `frame` conține cadrul adnotat (cu bounding box-uri și etichete deja desenate de modulul de fuziune), codificat **JPEG la calitate 75** și apoi **Base64**. Pentru a reduce volumul transmis, cadrul este redimensionat la o lățime maximă de 800 px înainte de codificare. Trebuie precizat că rezultatele detectiilor nu sunt grupate într-un singur câmp `detections`, ci în **câmpuri separate per detector** (`face_results`, `plate_results`, `fire_results`, `har_results`, `weapon_results`); fiecare este o listă de obiecte cu structură specifică detectorului (de exemplu, un rezultat facial conține `name`, `confidence`, `bbox`, `age`, `gender`, `emotion`). Câmpurile booleene `*_enabled` comunică frontend-ului ce module sunt active, astfel încât interfața să poată ascunde/afișa straturile corespunzătoare. Toate valorile trec prin `convert_to_serializable` pentru a transforma tipurile NumPy în tipuri native serializabile JSON.

Alarmerle nu sunt transmise printr-un tip de mesaj WebSocket separat; ele sunt stocate în baza de date și consultate de client prin endpoint-urile REST `/api/alarms` (§4.5). Captura asociată unei alarme (snapshot) este codificată tot JPEG+Base64, la calitate 60, în momentul declanșării.

Ciclul de viață complet al unei conexiuni este ilustrat în Figura 4.7: de la autentificare și handshake, prin alocarea cozii proprii și bucla de transmitere la ~30 FPS, până la deconectare și eliminarea cozii din dicționar.

4.6.3 Cadența de transmitere

Bucla de transmitere a fiecărui client consumă din *propria coadă* în mod ne-blocant (`get(block=False)`): dacă există un mesaj, îl trimite (`send_text(json.dumps(...))`); dacă nu, prinde `queue.Empty` și continuă. După fiecare iterație, bucla execută `await asyncio.sleep(0.03)`, ceea ce stabilește o cadență țintă de **aproximativ 30 FPS** (consistentă cu cerința NF1) și, în același timp, cedează controlul buclei de evenimente asincrone, permițând serverului să deservească în paralel ceilalți clienți și cererile REST.




Figura 4.7: Diagramă de secvență UML a ciclului de viață al unei conexiuni WebSocket: autentificare (validarea token-ului JWT, cu închidere 1008 la eșec), handshake (accept()), alocarea cozii proprii în `client_queues`, bucla de transmitere la ~30 FPS (firul de fuziune produce prin `_broadcast_frame`, endpoint-ul consumă neblocaant și trimite mesajele `video_frame`) și deconectarea, cu eliminarea cozii din dicționar.

4.6.4 Heartbeat și detectarea deconectării

Implementarea curentă nu folosește un heartbeat la nivel de aplicație (ping/pong explicit cu mesaje dedicate). Detectarea deconectării se bazează pe două mecanisme: (i) excepția `WebSocketDisconnect`, ridicată de FastAPI/Starlette atunci când clientul închide conexiunea, prinsă explicit în handler; și (ii) fluxul continuu de cadre, care joacă rolul unui heartbeat implicit – absența mesajelor pentru o perioadă, combinată cu eroarea la `send_text`, declanșează ieșirea din buclă. La nivel de transport, protocolul WebSocket peste TCP dispune de propriul mecanism de ping/pong de control, gestionat de bibliotecă, pe care implementarea se bazează pentru menținerea conexiunii. Indiferent de cauză, blocul `finally` asigură eliminarea cozii clientului din `client_queues` (sub protecția `client_lock`), prevenind acumularea de conexiuni moarte.

4.6.5 Reconectare

Reconectarea este responsabilitatea clientului, nu a serverului – serverul tratează fiecare conexiune ca efemeră și nu păstrează stare per client între conexiuni (este *stateless* din acest punct de vedere). La pierderea conexiunii, clientul React reia handshake-ul către `/ws`; deoarece serverul difuzează mereu cel mai recent cadru (mecanismul *ultimul cadru disponibil* din §5.7.2), un client reconectat își reia fluxul imediat, fără a fi nevoie de resincronizare sau de recuperarea cadrelor pierdute. Această alegere – de a nu garanta livrarea fiecărui cadru – este corectă pentru un sistem de supraveghere live, unde un cadru pierdut este irelevant atâta timp cât cel curent este actual.

4.7 Proiectarea bazei de date

Baza de date reprezintă nucleul central de stocare al sistemului. Toate informațiile care trebuie să supraviețuiască unei reporniri (utilizatori, persoane, *embedding*-uri faciale, plăcuțe, zone, camere, alarme și jurnale) sunt stocate aici, în timp ce structurile volatile (precum indexul FAISS și *cache*-ul de zone) sunt reconstruite pe baza acestor date la fiecare inițializare. Această secțiune prezintă schema reală implementată în `database_manager.py`, detaliind relațiile dintre tabele, cheile, indecșii, precum și motivarea alegerii acestui sistem de gestiune a bazelor de date.

4.7.1 Alegerea sistemului de baze de date

Sistemul folosește **PostgreSQL**, nu SQLite. Decizia este motivată de mai multe trăsături folosite efectiv în schemă, indisponibile sau slabe în SQLite:

- tipul **tablou** (`TEXT[]`) pentru câmpul `authorized_zones` al persoanelor;
- tipul **JSONB** pentru metadatele de detecție (`detection_metadata`, `details`), cu interogare și indexare nativă;

- tipul `BYTEA` pentru stocarea embedding-urilor faciale binare;
- **concurența reală** la scriere: aspect esențial, justificat de faptul că pipeline-ul multi-threaded (§4.4) scrie alarme și jurnale din firul de fuziune în paralel cu apelurile REST ale utilizatorilor. În această arhitectură, blocarea exclusivă a fișierului specifică SQLite ar deveni un factor limitativ critic pentru întregul sistem.

Conexiunea este configurată în `DB_CONFIG` către baza `facial_recognition` de pe `localhost`, cu credențiale dedicate (cerința NF3).

4.7.2 Diagrama entitate-relație

Figura 4.8 prezintă diagrama entitate-relație a schemei. Cheile primare surogat (`id`) sunt subliniate, iar cheile străine sunt marcate prin (FK) și legate de tabelul referit printr-o linie continuă, etichetată cu politica `ON DELETE` corespunzătoare. Cele patru relații impuse prin chei străine sunt de tip 1:N (notație *crow's-foot*): trei dintre acestea cu `ON DELETE CASCADE` (`face_embeddings` și `access_logs` către `persons`, respectiv `vehicle_access_logs` către `license_plates`), iar una cu `ON DELETE SET NULL` (`cameras` către `zones`). Liniile punctate marchează legăturile menținute exclusiv la nivel de aplicație, fără chei străine: cele patru câmpuri `camera_id` (de tip `VARCHAR`) către `cameras` și, cel mai important, relația dintre persoană și zonă. Aceasta din urmă *nu* trece printr-un tabel de joncțiune, ci este denormalizată sub forma unui atribut multi-valoare, `authorized_zones TEXT[]`, definit direct în tabelul `persons`, unde zonele sunt referite prin nume, nu prin constrângeri de tip FK.




Figura 4.8: Diagrama entitate-relație (ERD) a schemei PostgreSQL facial_recognition, cu cele zece tabele implementate în database_manager.py. Cheile primare (id) sunt subliniate, iar cele cinci constrângeri UNIQUE sunt marcate cu asterisc. Liniile punctate evidențiază legăturile logice neimpuse prin FK: cele patru câmpuri camera_id către cameras și relația persoană–zonă, denormalizată ca atribut multi-valoare authorized_zones TEXT[] pe persons (nu ca entitate asociativă). Tabelul users este independentă.

4.7.3 Tabelele principale

Schema reală conține zece tabele. Pentru a menține o concordanță cu implementarea, în continuare sunt utilizate denumirile exacte din modulul `database_manager.py`. Orice diferență între aceste denumiri tehnice și terminologia generică va fi semnalată explicit.

persons – persoanele înregistrate. `id` SERIAL PK; `name`; `employee_id` (UNIQUE NOT NULL); `department`; `authorized_zones` TEXT[]; `created_at`. *Observație de proiectare:* autorizarea pe zone este denormalizată ca tablou de nume de zone direct pe persoană, nu printr-un tabel de joncțiune `person_zone_authorization` separat. Compromisul: citire foarte rapidă a zonelor unei persoane (folosită intens de pipeline, cache-uită în `_person_zones_cache`), în schimbul pierderii integrității referențiale către `zones` (zonele sunt referite prin nume, nu prin FK).

face_embeddings – corespondentul `person_images` din cerință, dar stochează embedding-uri, nu imagini. `id` SERIAL PK; `person_id` INTEGER REFERENCES `persons(id)` ON DELETE CASCADE; `embedding` BYTEA NOT NULL (vectorul InsightFace 512-d serializat binar); `created_at`. Relația cu `persons` este 1:N (o persoană poate avea mai multe embedding-uri, câte unul per imagine înregistrată), iar ON DELETE CASCADE asigură ștergerea embedding-urilor odată cu persoana. Acest tabel este sursa din care se reconstruiește indexul FAISS la pornire.

access_logs – jurnalul accesărilor de persoane. `id` SERIAL PK; `person_id` REFERENCES `persons(id)` ON DELETE CASCADE; `camera_id`; `confidence`; `detected_at`.

license_plates – corespondentul `plates`. `id` SERIAL PK; `plate_number` VARCHAR(20) UNIQUE NOT NULL; `vehicle_type`; `owner_name`; `owner_id`; `is_authorized` BOOLEAN DEFAULT TRUE; `registration_date`; `expiry_date`; `notes`. Cheia naturală `plate_number` este folosită ca țintă de FK de către jurnalul vehiculelor.

vehicle_access_logs – jurnalul accesărilor de vehicule. `id` SERIAL PK; `plate_number` cu FOREIGN KEY (`plate_number`) REFERENCES `license_plates(plate_number)` ON DELETE CASCADE; `camera_id`; `confidence`; `vehicle_type`; `detected_at`; `image_path`; `is_authorized`.

users – conturile de utilizator. `id` SERIAL PK; `username` UNIQUE NOT NULL; `password_hash`; `role` VARCHAR(20) DEFAULT 'user'; `full_name`; `created_at`. Parola este stocată exclusiv ca hash (cerința NF3), iar role alimentează controlul de acces (§4.8).

alarms – corespondentul `alerts`. `id` SERIAL PK; `camera_id` NOT NULL; `type` NOT NULL; `severity` DEFAULT 'medium'; `status` DEFAULT 'unresolved'; `description`; `snapshot` (captura JPEG+Base64 la momentul declanșării);

detection_metadata JSONB; created_at; resolved_at; resolved_by; notes. Câmpurile resolved_* susțin ciclul de viață al alarmei (UC11).

zones – zonele de supraveghere. id SERIAL PK; name UNIQUE NOT NULL; description; is_restricted BOOLEAN DEFAULT FALSE; created_at.

cameras – registrul persistent de camere. id SERIAL PK; camera_id UNIQUE NOT NULL; name; zone_id INTEGER REFERENCES zones(id) ON DELETE SET NULL; location; stream_url; camera_type DEFAULT 'ip'; created_at. Politica ON DELETE SET NULL pe zone_id face ca ștergerea unei zone să lase camera fără zonă, nu să o șteargă.

detection_logs – corespondentul logs; istoricul complet al fiecărei detecții. id SERIAL PK; camera_id NOT NULL; type NOT NULL; subject; confidence; severity; status; details JSONB; created_at. Acesta este tabelul interogată de /api/logs și exportat ca CSV.

4.7.4 Chei primare și străine

Toate tabelele folosesc o cheie primară surogat id SERIAL (întreg auto-incrementat). Pe lângă chei primare, schema definește următoarele **chei străine** și politici de ștergere:

- face_embeddings.person_id → persons.id, ON DELETE CASCADE;
- access_logs.person_id → persons.id, ON DELETE CASCADE;
- vehicle_access_logs.plate_number → license_plates.plate_number, ON DELETE CASCADE;
- cameras.zone_id → zones.id, ON DELETE SET NULL.

Constrângeri de unicitate (UNIQUE) protejează persons.employee_id, license_plates.plate_number, users.username, zones.name și cameras.camera_id. *Notă:* legătura logică persoană-zonă și cea alarmă/jurnal-cameră (camera_id este VARCHAR, nu FK către cameras) nu sunt impuse prin chei străine, ci la nivel de aplicație – o decizie de proiectare care privilegiază viteza de scriere a jurnalelor în detrimentul integrității referențiale stricte.

4.7.5 Indexarea

Pentru a susține interogările frecvente (filtrare de jurnale, listare de alarme, căutare de plăcuțe), schema definește următorii indecși secundari:

- idx_plate_number pe license_plates(plate_number);
- idx_detlogs_created_at pe detection_logs(created_at DESC), idx_detlogs_type pe (type), idx_detlogs_camera pe (camera_id) – acoperă filtrele paginii de jurnale (interval de timp, tip, cameră);

- `idx_vehicle_access_time` pe `vehicle_access_logs(detected_at)`, `idx_vehicle_camera` pe `(camera_id)`;
- `idx_alarms_status`, `idx_alarms_type`, `idx_alarms_severity`, `idx_alarms_created_at` pe `alarms` – acoperă filtrarea și sortarea panoului de alarme;
- `idx_cameras_zone` pe `cameras(zone_id)`.

Indexul pe `created_at` DESC al jurnalului de detectii este deosebit de relevant: cele mai multe interogări afișează evenimentele recente în ordine descrescătoare, iar indexul descendent elimină nevoia unei sortări la fiecare cerere.

4.8 Proiectarea sistemului de control al accesului

Controlul accesului protejează operațiile sensibile ale sistemului împotriva utilizatorilor neautorizați și implementează cerința NF3. El are trei componente: un model RBAC cu două roluri, un mecanism de sesiune fără stare bazat pe JWT (cu revocare prin listă neagră) și o stocare sigură a parolelor. Toate sunt prezentate mai jos exact așa cum sunt implementate în `app.py` și `database_manager.py`, inclusiv singura limitare reziduală rămasă.

4.8.1 Modelul RBAC

Sistemul folosește un model **Role-Based Access Control** minimal, cu două roluri stocate în coloana `users.role`:

- **admin** – acces complet: configurare, gestiunea tuturor entităților, activarea/dezactivarea modulelor AI;
- **user** – rolul implicit (DEFAULT 'user'): acces operațional la vizualizare, alarme, jurnale și statistici, fără drept de configurare.

Aplicarea rolurilor se face prin sistemul de dependențe FastAPI. Două funcții-dependență stau la baza protecției:

- `get_current_user` – decodează și validează token-ul JWT din antetul `Authorization: Bearer` și, suplimentar, *re-verifică utilizatorul față de baza de date* (prin `get_user_by_id`): un cont șters este respins cu 401 "User no longer exists", iar rolul curent din DB este preferat în locul celui din token (posibil învechit). Orice endpoint care o folosește cere doar ca utilizatorul să fie *autentificat* (oricare rol).
- `require_admin` – compusă peste `get_current_user`, verifică suplimentar `role == "admin"` și, în caz contrar, ridică `HTTPException 403` cu mesajul "Admin access required".

Astfel, nivelul de permisiune al unui endpoint este declarat la definirea lui, prin tipul dependenței injectate (`Depends(require_admin)` vs. `Depends(get_current_user)`).

4.8.2 Matricea de permisiuni

Tabelul 4.3 rezumă, pe module, ce poate face fiecare rol, conform dependențelor injectate efectiv în cod.

Tabel 4.3: Matricea de permisiuni pe module și roluri.

Modul / operație	admin	user	ne-autentificat
Autentificare (/api/login)	✓	✓	✓
Gestiune persoane (CRUD, imagini, istoric)	✓	—	—
Gestiune plăcuțe (CRUD, istoric)	✓	—	—
Gestiune utilizatori (creare/modificare/ștergere)	✓	—	—
Toggle module AI (face/plate/fire/HAR/weapon)	✓	—	—
Creare/modificare/ștergere zone	✓	—	—
Creare/modificare/ștergere camere (DB)	✓	—	—
Control fluxuri video runtime (pornire/oprire, /api/streams)	✓	—	—
Stare sistem (/api/status) / listare camere active	✓	✓	—
Listare zone / camere (citire)	✓	✓	—
Statistici interne detectoare (/api/har/stats, /api/weapon/stats)	✓	✓	—
Vizualizare jurnale + export CSV (inclusiv /api/logs/vehicle)	✓	✓	—
Vizualizare + gestiune alarme (rezolvare)	✓	✓	—
Statistici (/api/stats)	✓	✓	—
Schimbare parolă cont propriu	✓	✓	—
Logout / revocare token propriu (/api/logout)	✓	✓	—

Acoperirea completă a endpoint-urilor. Toate rutele /api (cu excepția firească a /api/login) au o dependență de securitate injectată: operațiile cu efect – controlul fluxurilor video în timp real (POST /api/streams, DELETE /api/streams, DELETE /api/streams/{camera_id}) – necesită Depends(require_admin), iar endpoint-urile de citire operațională (/api/status, GET /api/streams, /api/har/stats, /api/weapon/stats, /api/logs/vehicle) necesită Depends(get_current_user). Astfel, nicio operație nu poate fi efectuată fără autentificare prealabilă.

4.8.3 Hashing-ul parolelor

Parolele nu sunt stocate niciodată în format clar (*plaintext*). Mecanismul de securizare utilizează algoritmul **bcrypt** (prin intermediul bibliotecii **bcrypt** din

Python). La crearea sau actualizarea unui cont, parola este procesată prin funcția `bcrypt.hashpw(password.encode(), bcrypt.gensalt())`. Rezultatul generat, care include valoarea aleatoare de tip *salt* și factorul de cost încorporat în șir, este salvat în coloana `users.password_hash VARCHAR(255)`. La autentificare, validarea se realizează prin `bcrypt.checkpw(password.encode(), password_hash.encode())` în cadrul metodei `authenticate_user`, care returnează datele utilizatorului *fără* câmpul `password_hash`. Utilizarea funcției `gensalt()` garantează un *salt* unic pentru fiecare parolă, în timp ce costul adaptiv al algoritmului `bcrypt` asigură rezistența împotriva atacurilor de tip *brute-force* și *rainbow table*.

4.8.4 Gestiunea sesiunii (JWT)

Sesiunile sunt fără stare (*stateless*): după autentificarea reușită, serverul emite un JSON Web Token semnat, pe care clientul îl atașează fiecărei cereri ulterioare în antetul `Authorization: Bearer <token>`; serverul nu păstrează o stare de sesiune *pozitivă* în memorie sau în baza de date. Singura stare reținută este o listă neagră de token-uri revocate (tabela `revoked_tokens`, detaliată mai jos), consultată la fiecare cerere pentru a permite delogarea efectivă înainte de expirare.

Parametrii concreți ai token-ului, din `app.py`:

- **Algoritm:** HS256 (HMAC-SHA256, semnătură simetrică).
- **Durată de viață:** 8 ore (`JWT_EXPIRATION_HOURS = 8`), prin câmpul `exp`.
- **Payload:** `sub` (username), `user_id`, `role`, `full_name`, `jti` (identificator unic de token, generat cu `uuid4` și folosit pentru revocare), `exp`, `iat`. Includerea lui `role` în token permite verificarea rolului fără o interogare suplimentară în baza de date la fiecare cerere.
- **Validare:** la decodare, `jwt.ExpiredSignatureError` produce 401 "Token has expired", iar `jwt.InvalidTokenError` produce 401 "Invalid token".

Cheia de semnare. Cheia de semnare (`JWT_SECRET`) este externalizată în mediul de execuție (variabila de mediu `JWT_SECRET`). Comportamentul sistemului în cazul absenței acesteia depinde de mediul de rulare, definit de variabila `APP_ENV`: în **producție** (`APP_ENV=production`), o cheie absentă sau mai scurtă de 32 de caractere oprește explicit pornirea aplicației (`RuntimeError, fail-fast`), prevenind emiterea de token-uri cu o cheie efemeră; în **dezvoltare**, sistemul recurge la o cheie aleatorie per-proces și doar avertizează la pornire. Astfel, capcana silențioasă prin care un deployment real ar fi putut rula pe o cheie temporară (cu invalidarea token-urilor la fiecare repornire) este eliminată.

Revocarea sesiunilor. Deși token-ul în sine este *stateless*, sistemul oferă revocare instantanee printr-o listă neagră (tabela `revoked_tokens`, cu cheie `jti`). Fiecare token primește la emitere un identificator unic `jti` (`uuid4`);

endpoint-ul `POST /api/logout` înscrie `jti`-ul curent în listă, iar dependența `get_current_user` respinge cu 401 "Token has been revoked" orice token revocat – verificare aplicată și la deschiderea canalului WebSocket (închidere 1008). Pe lângă aceasta, `get_current_user` re-validează la fiecare cerere identitatea față de baza de date, astfel încât ștergerea unui cont și schimbarea de rol au efect imediat. Intrările expirate din listă nu mai au efect și sunt curățate periodic (`purge_expired_revocations`), astfel încât dimensiunea tabelului rămâne mărginită.

Limitare reziduală. Lista neagră revocă token-uri *individuale* (de exemplu sesiunea curentă, la logout, sau un token compromis). Ea nu invalidează automat *toate* sesiunile active ale unui utilizator la schimbarea parolei, întrucât serverul nu cunoaște `jti`-urile token-urilor încă neprezentate. Scenariul "delogare de pe toate dispozitivele" ar necesita o extindere suplimentară – de exemplu o coloană `users.tokens_valid_after` comparată cu `iat` la fiecare cerere. Această limitare reziduală este consemnată ca parte a analizei critice a cerinței NF3.

4.9 Proiectarea logicii de alarmare

Logica de alarmare este punctul în care detecțiile brute ale modulelor AI devin evenimente acționabile pentru operator. Ea este implementată centralizat în firul de fuziune (§4.4.1), după ce toate rezultatele unui cadru au fost agregate, și are trei responsabilități: (i) evaluarea regulilor de declanșare, (ii) atribuirea unei severități, (iii) persistarea și difuzarea alarmei cu deduplicare. Această secțiune descrie regulile exact așa cum sunt implementate în `app.py`.

4.9.1 Reguli de declanșare

O alarmă este creată prin metoda `_create_alarm_if_needed(camera_id, alarm_type, severity, description, snapshot, metadata, dedup_subject)`. Regulile efective sunt următoarele:

Persoană necunoscută (tip face). Pentru orice rezultat facial cu `name == "Unknown"`, indiferent de zonă, se creează o alarmă de tip `face` cu severitate `critical` și descrierea `"Unauthorized person detected (...%)"`.

Persoană în zonă restricționată (tip `unauthorized_zone`). Verificarea suplimentară `_check_zone_authorization` se aplică doar dacă zona camerei are `is_restricted = TRUE`. În acest caz se creează o alarmă `unauthorized_zone` cu severitate `critical` în două situații: (a) *persoană necunoscută* în zona restricționată (`"Unknown person in restricted zone '...'"`), sau (b) *persoană cunoscută dar neautorizată* – recunoscută, dar al cărei `employee_id` nu apare în `authorized_zones` ale zonei (`"<nume> (<id>) in restricted zone '...' -- not authorized"`). O persoană recunoscută și autorizată nu generează nicio alarmă.

Armă detectată (tip weapon). Pentru orice rezultat din detectorul de arme se creează o alarmă **weapon**, cu severitatea preluată din rezultat (`r["severity"]`, implicit `critical`).

Foc/fum confirmat (tip fire). Se creează alarmă **fire** *doar* pentru rezultatele care au *ambele* câmpuri **confirmed** și **alert** adevărate – adică doar după confirmarea temporală pe fereastră multi-cadru (cerința F4). Severitatea este **critical** pentru clasa **fire** și **high** pentru **smoke**.

Acțiune periculoasă (tip har). Pentru orice rezultat HAR cu `class != "normal"` (fight, vandalism) se creează o alarmă **har**, cu severitatea preluată din rezultat (implicit **high**) și eticheta acțiunii în descriere.

Plăcuță neautorizată (tip plate). Pentru orice rezultat ANPR cu citire OCR validă (numărul plăcuței diferit de `None`/`""`/`"UNKNOWN"`) care *nu* este regăsit pe lista de plăcuțe autorizate, se creează o alarmă **plate** cu severitate **high** și descrierea `"Unauthorized vehicle <plate> detected (...%)"`, deduplicată pe numărul plăcuței. Rezultatele ANPR sunt în plus *jurnalizate* (prin `_log_detection_if_needed` cu tip **plate** și status `"authorized" / "unauthorized"`).

Notă. Spre deosebire de regula persoanelor, alarma de plăcuță este *globală* (nu depinde de zona camerei): o plăcuță este considerată neautorizată dacă numărul ei nu apare în baza de date, indiferent de cameră (vezi §4.1.1, F3 și F7).

4.9.2 Captura asociată (snapshot)

Când oricare regulă se declanșează pe un cadru, se captează un *snapshot*: cadrul adnotat este redimensionat la o lățime maximă de 400 px, codificat JPEG la calitate 60 și apoi Base64, fiind atașat alarmei (câmpul **snapshot** din tabela **alarms**). Calitatea redusă este o decizie deliberată de economisire a spațiului, întrucât snapshot-ul servește doar contextualizării vizuale a alarmei în panoul operatorului.

4.9.3 Niveluri de severitate și mapping pe tipuri de eveniment

Severitatea este un câmp text pe tabela **alarms**, cu valoarea implicită **medium** la nivel de schemă. Logica de alarmare produce două niveluri efective – **critical** și **high** –, valoarea **medium** rămânând doar ca implicit al coloanei. Tabelul 4.4 prezintă maparea tip-eveniment → severitate.

4.9.4 Deduplicarea temporală

Pentru a nu inunda operatorul cu alarme repetate pentru același eveniment continuu, fiecare creare de alarmă trece printr-un mecanism de **cooldown**. Cheia de

Tabel 4.4: Maparea tipurilor de eveniment pe severitate, conform implementării.

Tip alarmă	Condiție de declanșare	Severitate
face	persoană necunoscută (oriunde)	critical
unauthorized_zone	necunoscut/neautorizat în zonă restricționată	critical
weapon	armă detectată	critical (din rezultat)
fire	foc confirmat	critical
fire	fum confirmat	high
har	acțiune $\neq$ normal (fight, vandalism, ...)	high (din rezultat)
plate	plăcuță neautorizată (OCR valid, negăsită)	high

deduplicare este tripletul (`camera_id`, `alarm_type`, `dedup_subject`) – concatenat în forma "`camera_id:alarm_type:subiect`" – iar fereastra este `alarm_cooldown_seconds = 30`: dacă o alarmă cu aceeași cheie a fost creată în ultimele 30 de secunde, noua declanșare este ignorată. Verificarea și rezervarea slot-ului (actualizarea timestamp-ului) se fac sub `alarm_lock`, astfel încât două fire concurente să nu treacă ambele de poartă.

Componenta `dedup_subject` este cea care *distinge* detecțiile concurente de același tip, evitând să le colapseze într-o singură alarmă: persoanele necunoscute sunt diferențiate printr-un *bucket* de poziție al casetei (`_bbox_position_bucket`), persoanele recunoscute prin `employee_id`, acțiunile HAR prin clasa acțiunii, iar plăcuțele prin numărul lor. Armele folosesc drept subiect eticheta clasei returnate de detector; întrucât acesta este antrenat pe o singură clasă (`weapon`), subiectul este în practică constant, astfel încât alarmele de armă se deduplicatează efectiv pe perechea (`cameră`, `tip`). Consecința – opusă unei deduplicări pe simpla pereche (`cameră`, `tip`) – este că două persoane necunoscute diferite, apărute simultan pe aceeași cameră, produc *două* alarme distincte, nu una. Dacă `dedup_subject` lipsește, mecanismul recade pe deduplicarea per (`cameră`, `tip`), ca mod implicit.

Pe lângă poarta din memorie (care se pierde la repornire), există un **backstop în baza de date**: înainte de a persista o alarmă, sistemul verifică prin `get_recent_alarm` dacă există deja o alarmă recentă, nerezolvată, cu aceeași cheie (inclusiv `dedup_subject`, păstrat în metadata), prevenind o rafală de duplicate imediat după ce serverul revine. Pentru comparație, jurnalizarea folosește propriul cooldown, mai scurt și pe subiect explicit (`log_cooldown_seconds = 5`).

Figura 4.9 sintetizează întreaga decizie de alarmare pentru un cadru, de la rezultatele agregate până la persistarea alarmei prin poarta comună de deduplicare.




Figura 4.9: Diagrama de flux a deciziei de alarmare pentru un cadru. Pornind de la rezultatele agregate în firul de fuziune, cele șase verificări sunt evaluate *independent* și secvențial, astfel încât un singur cadru poate genera mai multe alarme. Fiecare ramură stabilește tipul, severitatea și `dedup_subject`, după care alarma trece printr-o poartă comună: cooldown de 30 s pe cheia (`cameră`, `tip`, `subiect`) (sub `alarm_lock`) și un *backstop* în baza de date împotriva duplicatelor recente nerezolvate, înainte de persistare și difuzare în interfață.

4.10 Proiectarea interfeței utilizator

Interfața utilizator este punctul de contact dintre operator și sistem; ea trebuie să facă vizibile, într-un mod imediat și neambiguu, fluxurile live, alarmele și starea entităților. Frontend-ul este o aplicație React (vezi §4.3.1), organizată ca un *single-page application* cu o bară laterală de navigare și un panou central de conținut care comută între ecranele descrise mai jos. Această secțiune prezintă structura de navigare, wireframe-urile ecranelor principale și principiile UX urmărite, raportate la implementarea efectivă din `frontend/src`.

4.10.1 Structura de navigare

Navigarea este controlată de componenta `Sidebar`, care definește nouă ecrane, fiecare cu un indicator `adminOnly` ce determină vizibilitatea în funcție de rol (mecanism aliniat cu RBAC-ul din §4.8):

- accesibile tuturor (`adminOnly: false`): *Dashboard, Alarms, Logs*;
- rezervate administratorului (`adminOnly: true`): *Person Management, Zone Management, Camera Management, Plate Management, Statistics, User Management*.

Filtrarea elementelor de meniu se face în client (`allNavItems.filter(item => !item.adminOnly || isAdmin)`), astfel încât un operator cu rol `user` nu vede deloc rutele de administrare. Aceasta este o protecție de *uzabilitate*, dublată pe server de verificările `require_admin` (protecția de securitate propriu-zisă).

4.10.2 Principii UX

Feedback vizual imediat. Fiecare acțiune produce un răspuns vizibil: stările `isLoading` pe butoane în timpul cererilor, mesaje de eroare/succes, indicatorul de conexiune WebSocket (`isConnected`) pe dashboard, și suprapunerea în timp real a detecțiilor peste fluxul video. Severitatea alarmelor este codată cromatic pentru identificare rapidă.

Confirmări pentru acțiuni distructive. Toate ștergerile cer o confirmare explicită prin dialog, cu mesaj care explică *consecințele*, nu doar acțiunea. De exemplu, ștergerea unei persoane avertizează că *toate datele faciale vor fi eliminate și persoana nu va mai fi recunoscută*, iar ștergerea unei zone avertizează că *camerele din ea vor rămâne neasignate, iar persoanele își vor pierde această zonă din lista autorizată*. Aceste confirmări sunt prezente în `PersonManagement`, `PlateManagement`, `ZoneManagement`, `CameraManagement` și `UserManagement`.

Filtrare consistentă. Tabelele cu volum mare de date oferă filtrare uniformă: pagina de *Alarme* filtrează pe status/tip/severitate, pagina de *Jurnale*

pe tip/status/interval de timp/căutare, ambele cu paginare. Filtrele sunt transmise ca parametri de query către endpoint-urile REST corespunzătoare, deci filtrarea se face pe server, nu în client – important pentru seturi mari de date.

Layout responsive. Stilizarea cu Tailwind folosește clase responsive (`sm:`, `md:`, `lg:`, `grid-cols-*`) în toate componentele majore, astfel încât interfața să fie utilizabilă atât pe stația fixă a dispecerului, cât și pe dispozitive mobile pentru supraveghere de la distanță (cerința NF8).

Capitolul 5: Implementarea Modulelor de Inteligență Artificială

5.1 Modulul de recunoaștere facială

Modulul de recunoaștere facială constituie componenta centrală a sistemului de control al accesului și este implementat în clasa `FacialRecognitionSystem` din fișierul `facial_recognition_system.py`. Rolul său este de a identifica, în fiecare cadru video, persoanele înregistrate anterior în baza de date și de a distinge între persoanele cunoscute (angajați) și cele necunoscute. Spre deosebire de pipeline-urile clasice de recunoaștere facială, care înlanțuie un detector de fețe, un model separat de extragere a embeddings-urilor și încă unul pentru estimarea atributelor demografice, implementarea de față consolidează toate aceste sarcini într-o singură trecere prin pachetul de modele `buffalo_s` al framework-ului InsightFace, ale cărui fundamente teoretice au fost prezentate în secțiunea 3.3.

Pipeline-ul intern al modulului are patru etape, descrise în subcapitolele care urmează: (1) detecția fețelor și extragerea embeddings-urilor cu InsightFace, (2) indexarea și căutarea vectorilor cu FAISS, (3) strategia de stabilire a identității pe baza distanței și (4) optimizarea prin omiterea analizei demografice pentru fețele deja recunoscute. La nivelul aplicației, modulul rulează într-un fir de execuție dedicat (*Thread 2*), care preia cadre dintr-o coadă de tip `queue.Queue`, apelează metoda `process_frame()` și publică rezultatele în coada de fuziune (a se vedea secțiunea 5.7).

5.1.1 Detecția fețelor și extragerea embeddings-urilor

Detecția fețelor și extragerea descriptorilor numerici (embeddings) sunt realizate de obiectul `FaceAnalysis` din InsightFace, inițializat cu pachetul de modele `buffalo_s`. Acest pachet reunește trei submodele care, în abordarea tradițională, ar fi necesitat încărcarea și apelarea separată:

- **det_500m** – detectorul de fețe, care returnează bounding box-ul și cele cinci puncte caracteristice (landmark-uri) pentru fiecare față din cadru;

- **w600k_mbf** – rețeaua de recunoaștere, o variantă MobileFaceNet antrenată pe datasetul Glint360K cu funcția de pierdere ArcFace, care produce embedding-ul facial de 512 dimensiuni;
- capul **genderage** – care estimează vârsta și genul persoanei.

Alegerea variantei **buffalo_s** (în locul, de exemplu, a variantei **buffalo_sc**) este motivată tehnic: rețeaua de recunoaștere **w600k_mbf** este identică în ambele pachete, astfel încât embedding-urile de 512 dimensiuni rămân compatibile, însă **buffalo_s** include modulul suplimentar **genderage**, indispensabil pentru analiza demografică (secțiunea 5.2). În lipsa acestui modul de predicție, estimările privind vârsta și genul ar fi indisponibile, sistemul returnând valoarea **None**.

Pentru fiecare cadru, metoda **process_frame()** apelează **self.face_app.get(frame)**, care efectuează într-o singură trecere detecția tuturor fețelor și, pentru fiecare, calculează bounding box-ul, landmark-urile, embedding-ul L2-normalizat (**normed_embedding**, vector de 512 de elemente de tip **float32**) și estimările de vârstă și gen. Bounding box-ul de tip **[x1, y1, x2, y2]** returnat de InsightFace este convertit în formatul **(x, y, w, h)** și ancorat în limitele cadrului de metoda statică **_bbox_xyxy_to_xywh()**, pentru a evita decupaje în afara imaginii.

5.1.1.1 Configurarea execuției pe GPU

Inferența InsightFace rulează pe GPU prin runtime-ul ONNX, providerul **CUDAExecutionProvider** fiind configurat explicit cu opțiunea **cudnn_conv_algo_search="HEURISTIC"**. Această opțiune este o decizie de implementare importantă în contextul arhitecturii multi-threaded a aplicației: strategia implicită, **EXHAUSTIVE**, măsoară empiric timpul fiecărui algoritm de convoluție folosind mecanismul de *stream capture* al CUDA. Cum InsightFace rulează concurent cu modelele PyTorch (YOLO pentru plăcuțe, foc și arme, respectiv SlowFast pentru acțiuni) pe același GPU, o astfel de captură în desfășurare ar întrerupe orice kernel PyTorch paralel cu eroarea *“operation not permitted when stream is capturing”*. Varianta **HEURISTIC** selectează algoritmul pe baza unor euristici, fără benchmarking și deci fără captură, eliminând coliziunile între firele de execuție.

5.1.1.2 Gestionarea bibliotecilor CUDA și a TensorFlow

La importul modulului, funcția **_preload_nvidia_pypi_libs()** preîncarcă explicit, prin **ctypes.CDLL(..., RTLD_GLOBAL)**, bibliotecile partajate CUDA, cuDNN și cuBLAS livrate în pachetele pip **nvidia-*-cu12**, astfel încât **onnxruntime** să le poată găsi fără a necesita setarea manuală a variabilei **LD_LIBRARY_PATH**. În plus, TensorFlow (folosit de modelul de emoții) este forțat să nu folosească GPU-ul prin **set_visible_devices([], "GPU")**, deoarece menținerea lui pe GPU provoacă conflicte de context CUDA cu **onnxruntime-gpu** și **segmentation fault** la inițializare.

5.1.1.3 Înregistrarea persoanelor

Embedding-urile persoanelor cunoscute sunt generate în momentul înregistrării acestora în sistem. Metoda `register_person()` primește o listă de imagini faciale și execută modelul InsightFace pe fiecare dintre ele. În situația în care sunt detectate mai multe fețe într-o imagine, sistemul o selectează pe cea cu aria maximă a casetei de încadrare (*bounding box*), prin intermediul funcției `_extract_single_face()`. Ulterior, este extras *embedding*-ul de 512 dimensiuni, care va fi stocat atât în baza de date, cât și în indexul FAISS. Pentru încărcările de imagini efectuate prin interfața web, metoda `extract_embedding_from_image()` acceptă exclusiv imaginile care conțin o singură față detectabilă, prevenind astfel riscul asocierii ambigue a unui *embedding* cu o persoană.

5.1.2 Indexarea cu FAISS FlatL2

Căutarea identității unei fețe presupune compararea embedding-ului ei cu toți descriptorii persoanelor înregistrate. Pentru a face această operație eficientă, sistemul folosește biblioteca FAISS, încapsulată în clasa `FaissIndex` din fișierul `faiss_index.py`. Tipul de index utilizat este *IndexFlatL2*, care realizează o căutare *exactă* (*brute-force*) folosind distanța euclidiană L2 între vectorul de interogare și fiecare vector din index. Spre deosebire de indecșii aproximativi (precum IVFFlat), căutarea exactă nu necesită o etapă de antrenare și garantează găsirea celui mai apropiat vecin; aceasta este alegerea potrivită pentru dimensiunea tipică a unei baze de angajați, unde numărul de embedding-uri este suficient de mic încât căutarea liniară să rămână instantanee.

5.1.2.1 Maparea identităților

FAISS operează cu indici poziționali interni (0, 1, 2, ...), nu cu identificatorii persoanelor din baza de date. De aceea, clasa `FaissIndex` menține două dicționare de mapare: `id_map`, care asociază fiecărui index FAISS un `person_id`, și `reverse_id_map`, care leagă fiecare `person_id` de lista de indici corespunzători (o persoană poate avea mai multe embedding-uri, câte unul pentru fiecare imagine înregistrată).

5.1.2.2 Persistența și reconstrucția indexului

Indexul FAISS este o structură de date alocată în memorie, în timp ce baza de date PostgreSQL constituie punctul central de stocare și referință pentru toți vectorii de *embedding*. În tabelul `face_embeddings`, fiecare *embedding* este salvat în coloana `embedding` de tip `BYTEA`, fiind serializat cu ajutorul bibliotecii `pickle`. La pornirea sistemului, metoda `_load_embeddings_from_db()` preia toate datele prin `get_all_embeddings()` și reconstruiește complet indexul prin apelarea funcției `rebuild_index()`. Această procedură de reconstrucție este declanșată automat ori de câte ori o persoană este înregistrată, modificată sau ștearsă, garantând astfel consistența strictă între stocarea persistentă și indexul volatil.

5.1.2.3 Siguranța accesului concurent

Întrucât firul de recunoaștere facială interoghează indexul în fiecare cadru, în timp ce firele care deservesc cererile HTTP îl pot reconstrui (la înregistrarea sau ștergerea persoanelor), iar operațiile `add/search` ale FAISS nu sunt sigure pentru execuția concurentă, toate accesările indexului și ale dicționarelor de mapare sunt serializate cu un lock reentrant (`threading.RLock`). Caracterul reentrant este necesar deoarece `rebuild_index()` apelează intern `add_embeddings_batch()`, care preia același lock.

5.1.3 Strategia de matching

Stabilirea identității unei fete pe baza distanței euclidiene este implementată în metoda `_match_embedding()`. Aceasta interoghează mai întâi indexul pentru cel mai apropiat vecin ($k=1$) cu un prag “infinit”, astfel încât distanța reală până la cel mai apropiat vector să poată fi înregistrată pentru calibrare (activabilă prin variabila de mediu `FR_DEBUG`), după care aplică manual pragul de decizie configurat.

5.1.3.1 De la distanța L2 la similaritatea cosinus

Deoarece embeddings-urile sunt L2-normalizate, între distanța euclidiană la pătrat și similaritatea cosinus a doi vectori există relația exactă $L2^2 = 2 - 2 \cos \theta$, echivalentă cu $\cos \theta = 1 - L2^2/2$. Această echivalență permite raportarea identității prin două mărimi interpretabile:

- `recognition_threshold = 1.0` – pragul aplicat distanței L2. Un prag $L2 = 1,0$ corespunde unei similarități cosinus de 0,5. Empiric, distribuția distanțelor pentru aceeași persoană se situează în intervalul $[0,6; 0,85]$ pe camera web folosită, deci un candidat cu $L2 \geq 1,0$ este respins ca necunoscut;
- `min_confidence = 0.4` – pragul aplicat încrederii, exprimată ca similaritate cosinus. Valoarea 0,4 este punctul de operare clasic “aceeași persoană” pentru ArcFace.

Dacă distanța celui mai apropiat vecin depășește `recognition_threshold`, metoda returnează `None` (față necunoscută). În caz contrar, distanța este convertită în similaritate cosinus, mărginită la intervalul $[0; 1]$ și raportată ca nivel de încredere; identificatorul persoanei este apoi rezolvat în datele complete (nume, ID angajat, departament) prin `get_person_by_id()`. În metoda `process_frame()`, o față este considerată cunoscută doar dacă există o potrivire și încrederea ei depășește `min_confidence`. Pentru fiecare potrivire validă se înregistrează un eveniment de acces în baza de date prin `log_access()`.

Vizual, fețele cunoscute sunt marcate cu un chenar verde și eticheta `nume` (`încredere`), iar cele necunoscute cu un chenar portocaliu și eticheta `Unknown`, prin metoda `_draw_face()`.

5.1.4 Optimizarea: omiterea analizei demografice pentru fețele cunoscute

O optimizare deliberată la nivelul *pipeline*-ului de procesare facială constă în condiționarea analizei demografice de rezultatul etapei de recunoaștere. În cadrul funcției `process_frame()`, atributele demografice (precum vârsta și genul, generate de modulul `genderage` al arhitecturii InsightFace, alături de emoția prezisă de rețeaua Mini-Xception, detaliată în Secțiunea 5.2) sunt calculate *exclusiv pentru fețele necunoscute*. În cazul unei persoane identificate cu succes, câmpurile `age`, `gender`, `emotion` și `emotion_confidence` sunt inițializate direct cu valoarea `None`.

Raționamentul are atât o componentă de proiectare, cât și una de performanță. Din perspectivă semantică, calcularea informațiilor demografice pentru o persoană deja recunoscută reprezintă o operațiune redundantă, întrucât identitatea, vârsta exactă și departamentul sunt deja disponibile în baza de date. Din punct de vedere al performanței, această decizie elimină necesitatea unei treceri suplimentare (*forward-pass*) prin rețeaua de clasificare a emoțiilor pentru fețele cunoscute, la fiecare cadru. Economia de resurse este considerabilă, în special pentru că inferența rețelei Mini-Xception se execută pe unitatea CPU. Prin urmare, costul computațional aferent analizei demografice este asumat doar atunci când generează informație utilă, adică în cazul persoanelor neidentificate, pentru care caracterizarea demografică și emoțională devine relevantă în scenariile de supraveghere.

5.2 Analiza demografică și emoțională

Pe lângă identificarea persoanelor cunoscute, sistemul caracterizează demografic și emoțional persoanele *necunoscute*, adică acele fețe care nu pot fi asociate niciunei intrări din baza de date. Această analiză produce trei atribute pentru fiecare astfel de față: vârsta estimată, genul și emoția. Implementarea este integrată în aceeași clasă `FacialRecognitionSystem` și în aceeași metodă `process_frame()` ca recunoașterea facială, evitând o trecere separată de detecție a fețelor. După cum a fost detaliat în secțiunea 5.1.4, aplicarea analizei demografice este strict condiționată (vizând exclusiv fețele necunoscute), întrucât estimarea acestor atribute devine redundantă în cazul persoanelor deja identificate.

Extragerea atributelor se bazează pe două modele distincte: vârsta și genul sunt furnizate de modulul `genderage` din cadrul arhitecturii InsightFace (deja evaluat implicit prin execuția pachetului `buffalo_s`), în timp ce starea emoțională este estimată de o rețea convoluțională independentă, Mini-Xception, aplicată direct pe regiunea facială decupată (*face crop*).

5.2.1 Estimarea vârstei și genului

Vârsta și genul nu necesită un model dedicat: ambele sunt generate de modulul `genderage` al pachetului `buffalo_s`, în aceeași trecere InsightFace care furni-

zează bounding box-ul, landmark-urile și embedding-ul. Pentru fiecare obiect **Face** returnat de detector, atributele sunt extrase astfel:

- **Vârsta** – câmpul `face.age` (valoare reală) este rotunjit la cel mai apropiat întreg. Dacă atributul lipsește, vârsta este raportată ca `None`;
- **Genul** – câmpul `face.gender` este o valoare întreagă în convenția InsightFace (1 = masculin, 0 = feminin), care este tradusă în etichetele textuale "Man", respectiv "Woman".

Această abordare nu adaugă cost de inferență suplimentar: estimările sunt deja calculate de InsightFace, fiind doar citite și formate. (secțiunea 5.1.1).

5.2.2 Recunoașterea emoțiilor cu Mini-Xception

Spre deosebire de vârstă și gen, emoția este clasificată de un model separat: Mini-Xception, o rețea neuronală convoluțională compactă furnizată de pachetul Python `fer` sub forma fișierului de ponderi `emotion_model.hdf5`. Modelul este antrenat pe datasetul FER-2013 și clasifică expresia facială într-una din șapte categorii, ordonate conform ieșirilor softmax ale modelului în tuplul `_EMOTION_LABELS`: `angry`, `disgust`, `fear`, `happy`, `sad`, `surprise` și `neutral`.

Un aspect important al implementării este faptul că API-ul implicit al pachetului `fer` este *ocolit complet*. Pachetul `fer` efectuează în mod normal propria sa detecție de fețe cu un clasificator Haar cascade înainte de a clasifica emoția – o trecere redundantă, întrucât InsightFace a detectat deja toate fețele din cadru. În locul acestui flux, modelul Mini-Xception este încărcat direct prin `tf.keras.models.load_model()` (cu `compile=False`) și este alimentat cu crop-ul facial deja delimitat de bounding box-ul InsightFace. Astfel se elimină o detecție de fețe duplicată și se garantează că emoția este clasificată exact pe regiunea identificată de pipeline-ul principal.

Predicția propriu-zisă, implementată în metoda `_classify_emotion()`, constă într-o etapă de propagare directă (*forward pass*) prin rețea, urmată de aplicarea operației `argmax` pe cele șapte probabilități furnizate de funcția *softmax*. Rezultatul returnat este un tuplu format din eticheta emoției și scorul de confidență asociat. Dimensiunea de intrare necesară modelului este extrasă automat din proprietatea `input_shape`, asigurând astfel adaptarea dinamică a etapei de preprocesare (detaliată în continuare) la arhitectura specifică rețelei.

5.2.3 Preprocesarea crop-ului facial

Înainte de a fi evaluat de rețeaua de clasificare a emoțiilor, decupajul facial (extras din imaginea de ansamblu pe baza casetei de încadrare furnizate de InsightFace, în format BGR) parcurge o etapă riguroasă de preprocesare. Acest proces reproduce fidel fluxul intern de prelucrare al pachetului `fer`, garantând astfel faptul că ponderile antrenate ale modelului primesc datele de intrare exact în distribuția statistică necesară. Pașii de transformare, implementați în cadrul metodei `_classify_emotion()`, sunt următorii:

1. **Conversia în tonuri de gri:** regiunea facială în format BGR este convertită în scară de gri utilizând funcția `cv2.cvtColor`, deoarece modelul Mini-Xception procesează exclusiv imagini cu un singur canal de culoare;
2. **Redimensionarea:** imaginea rezultată este adusă la dimensiunile de intrare impuse de model (la valoarea `_emotion_target_size`, dedusă dinamic din atributul `input_shape`);
3. **Normalizarea:** intensitatea pixelilor este scalată din intervalul $[0, 255]$ în intervalul $[0, 1]$ (prin împărțire la 255), fiind ulterior mapată în intervalul $[-1, 1]$ aplicând transformarea matematică $(x - 0.5) \cdot 2$;
4. **Extinderea dimensionalității tensorului:** matricea bidimensională este remodelată la forma $(1, H, W, 1)$ (adăugându-se dimensiunea lotului de prelucrare, *batch size*, și axa canalului), acesta fiind formatul structural așteptat de modelele Keras.

Întregul lanț este protejat de un bloc `try/except`: dacă, din orice motiv, crop-ul este gol sau preprocesarea eșuează, metoda returnează `(None, None)`, iar fața este raportată fără emoție, fără a întrerupe procesarea celorlalte fețe din cadru.

5.2.4 Inferența pe CPU

Spre deosebire de InsightFace, care rulează pe GPU, rețeaua Mini-Xception este rulată deliberat pe CPU. Această decizie este aplicată chiar la importul modulului, unde TensorFlow este forțat să nu vadă niciun dispozitiv GPU prin `tf.config.set_visible_devices([], "GPU")`.

Motivația este dublă. În primul rând, menținerea TensorFlow pe GPU în paralel cu `onnxruntime-gpu` (folosit de InsightFace) provoacă conflicte de context CUDA și `segmentation fault` la inițializare; izolarea TensorFlow pe CPU elimină complet această sursă de instabilitate. În al doilea rând, Mini-Xception este o rețea suficient de mică încât latența inferenței pe CPU să fie neglijabilă, iar emoția se calculează doar pentru fețele necunoscute (secțiunea 5.1.4); prin urmare, costul pe CPU este minor, iar GPU-ul rămâne dedicat integral modelelor grele.

5.3 Modulul de recunoaștere a plăcuțelor de înmatriculare

Modulul de recunoaștere a plăcuțelor de înmatriculare (ANPR – *Automatic Number Plate Recognition*) identifică și citește numerele de înmatriculare ale vehiculelor din fluxul video, le validează formatul, le caută în baza de date și decide dacă vehiculul este autorizat. Modulul este implementat în clasa `LicensePlateRecognitionSystem` din fișierul `license_plate_recognition_system.py` și rulează într-un fir de execuție dedicat (*Thread 3*).

Pipeline-ul combină un detector de obiecte (YOLOv8) cu un motor de recunoaștere optică a caracterelor (EasyOCR), între care se interpun mai mulți pași de preprocesare a imaginii și, ulterior, o etapă de stabilizare temporală a rezultatului. O provocare majoră, care a influențat semnificativ implementarea, este faptul că plăcuțele apar în cadru la rezoluții reduse (tipic 116–151 px lățime), insuficiente pentru o recunoaștere OCR fiabilă. Din acest motiv, *pipeline*-ul include un pas explicit de mărire a imaginii (*up-scaling*) și o etapă avansată de filtrare și accentuare a detaliilor. Cele opt subcapitole care urmează descriu, în ordinea execuției, etapele acestui flux de prelucrare.

5.3.1 Detecția plăcuțelor cu YOLOv8

Localizarea plăcuțelor în cadru este realizată cu ajutorul unui model YOLOv8, instanțiat prin intermediul clasei `YOLO` din pachetul `ultralytics`, pe baza fișierului de ponderi `models/license_plate/best.pt`. Modelul de bază utilizat este `harshitsingh09/yolov8-license-plate-detector`, o variantă a arhitecturii YOLOv8 publicată pe platforma Kaggle și dedicată exclusiv detecției plăcuțelor de înmatriculare (având definită o singură clasă, `license_plate`). Modelul a fost integrat în sistem în forma sa originală, fără a necesita o etapă suplimentară de antrenare (*fine-tuning*) în cadrul acestui proiect. La momentul inițializării, pentru a optimiza viteza de inferență, sistemul verifică disponibilitatea mediului CUDA și, în caz afirmativ, transferă execuția modelului pe unitatea GPU.

Pentru fiecare cadru procesat, metoda `process_frame()` apelează funcția `predict()` utilizând parametrul `imgsz=640` și un prag de confidență `conf=0.25`, extrăgând astfel casetele de încadrare candidate (*bounding boxes*). Fiecare casetă, definită prin coordonatele `[x1, y1, x2, y2]`, este ulterior *extinsă* cu 20% în toate direcțiile prin intermediul funcției `expand_bbox()` (utilizând un coeficient `pad_ratio` de 0.20). Această margine de siguranță mai generoasă garantează includerea limitelor fizice ale plăcuței alături de un context vizual minim, prevenind astfel decuparea accidentală a caracterelor aflate la extremități înaintea evaluării OCR. Regiunea decupată rezultată este transmisă etapelor ulterioare de prelucrare.

5.3.2 Up-scaling-ul plăcuțelor mici

Deoarece plăcuțele detectate prezintă frecvent dimensiuni insuficiente pentru o recunoaștere OCR precisă, regiunea decupată este procesată de funcția `upscale_if_small()`, având ca scop redimensionarea la o lățime țintă de 250 px. Algoritmul aplică următoarea regulă: dacă lățimea curentă se situează sub acest prag, se calculează un factor de scalare $scale = 250/w$. Acesta este limitat superior la valoarea 3.0 pentru a preveni amplificarea excesivă a zgomotului de imagine. Redimensionarea propriu-zisă utilizează interpolarea bicubică (`cv2.INTER_CUBIC`), selectată datorită calității superioare a reconstrucției detaliilor în procesul de suprascalară. Casetele care îndeplinesc deja criteriul

de lățime minimă rămân nemodificate. Printr-o astfel de operațiune, o regiune inițială de 116×33 px este transformată într-o imagine de aproximativ 250×70 px, rezoluție la care performanța algoritmului OCR atinge un nivel optim de fiabilitate.

5.3.3 Pipeline-ul de preprocesare pentru OCR

Imaginea mărită este ulterior pregătită pentru etapa de recunoaștere optică a textului (OCR) prin intermediul funcției `preprocess_plate()`. Aceasta aplică o secvență de patru operații, optimizată special pentru a maximiza performanța algoritmului EasyOCR în identificarea plăcuțelor de înmatriculare:

1. **Conversie în tonuri de gri** – imaginea color este transformată în grayscale;
2. **Filtru bilateral** (`cv2.bilateralFilter` cu $d = 11$ și sigma de culoare și de spațiu de 17) – reduce zgomotul, păstrând în același timp muchiile caracterelor;
3. **Egalizare locală de histogramă CLAHE** (`clipLimit=2.0`, `tileGrid Size=(8, 8)`) – compensează umbrele și iluminarea neuniformă;
4. **Unsharp mask** – accentuează muchiile caracterelor după mărire, construit ca diferență ponderată între imaginea originală (coeficient 1,5) și o versiune blurată Gaussian cu $\sigma = 1,0$ (coeficient $-0,5$).

O decizie deliberată este aceea de *a nu binariza* imaginea: modelul CRNN folosit de EasyOCR oferă rezultate mai bune pe imagini continue în tonuri de gri decât pe imagini cu prag aplicat. Pipeline-ul se oprește, prin urmare, la o imagine grayscale curățată și accentuată, nu la o imagine alb-negru.

5.3.4 Apelul EasyOCR

Citirea propriu-zisă a caracterelor este realizată de EasyOCR în metoda `_run_ocr()`. Apelul `reader.readtext()` este parametrizat specific pentru plăcuțe:

- `allowlist` restrânge alfabetul recunoscut la literele mari A-Z și cifrele 0-9, eliminând caracterele imposibile pe o plăcuță;
- `text_threshold=0.6`, `low_text=0.3` și `mag_ratio=1.5` reglează sensibilitatea detecției de text și mărirea internă a EasyOCR;
- `paragraph=False` dezactivează gruparea în paragrafe, nepotrivită pentru un singur rând de caractere.

Întrucât EasyOCR poate returna mai multe fragmente de text (de exemplu, grupul de litere și cel de cifre separat), fragmentele sunt sortate de la stânga la dreapta după coordonata x a colțului stânga-sus, apoi sunt curățate (păstrând doar caractere alfanumerice, transformate în majuscule) și concatenate într-un singur șir. Încrederea raportată este media aritmetică a încrederilor fragmentelor componente.

5.3.5 Fallback pe imaginea color

Preprocesarea agresivă (grayscale, filtrare, CLAHE, unsharp) îmbunătățește citirea în majoritatea cazurilor, dar în anumite condiții de iluminare poate degrada rezultatul. Pentru a acoperi aceste situații, pipeline-ul include un mecanism de *fallback*: dacă citirea de pe imaginea preprocesată este goală sau are o încredere sub 0.4, OCR-ul este reluat pe decupajul color original (nepreprocesat). Dacă această a doua citire are o încredere mai mare, ea o înlocuiește pe prima. Astfel, sistemul nu rămâne blocat pe o preprocesare care, ocazional, dăunează în loc să ajute.

5.3.6 Tracking-ul plăcuțelor între cadre

Extragerea textului dintr-un singur cadru este o abordare predispusă la erori, deoarece algoritmul OCR poate confunda cu ușurință caractere similare din punct de vedere vizual (precum 0 și O, sau B și 8) de-a lungul cadrelor succesive. Pentru a garanta stabilitatea rezultatului, fiecare detecție este monitorizată temporal prin intermediul clasei `PlateTracker`. Asocierea unei noi detecții cu o traiectorie existentă (*track*) se realizează evaluând suprapunerea spațială: se calculează metrica *IoU* (*Intersection over Union*, prin apelul funcției `_iou()`) între caseta de încadrare curentă și casetele traiectoriilor active. Detecția este atribuită traiectoriei care prezintă valoarea maximă a metricei IoU, cu condiția ca aceasta să depășească pragul minim definit de `iou_threshold=0.3`. În situația în care nu se identifică nicio corespondență validă, sistemul inițializează o nouă traiectorie, alocându-i un identificator unic.

Fiecare traiectorie menține un istoric al citirilor recente, stocat într-o structură de date liniară cu capacitate limitată (un obiect `deque` configurat cu parametrul `history=10`). Suplimentar, entitatea folosește parametrul de stare `age`, care contorizează numărul de cadre consecutive în care respectiva traiectorie nu a primit actualizări. La procesarea fiecărui cadru, metoda `age_tracks()` incrementează acest contor de inactivitate pentru toate traiectoriile monitorizate, eliminându-le automat pe cele care depășesc pragul `max_age=15` cadre. Acest mecanism asigură oprirea urmăririi pentru vehiculele care au părăsit câmpul vizual al camerei.

5.3.7 Validarea formatului

Înainte de a fi inclusă în procesul decizional de agregare, fiecare citire este validată în raport cu formatul standard al plăcuțelor de înmatriculare din România, prin intermediul expresiei regulate `ROMANIAN_PLATE_RE`. Această regulă acceptă configurații formate din una sau două litere pentru indicativul județului, urmate de două sau trei cifre și un grup final de trei litere (de exemplu, `CJ12ABC` sau, specific pentru București, `B123ABC`). În cadrul metodei `PlateTracker.update()`, un rezultat OCR este adăugat în istoricul instanței de urmărire exclusiv dacă îndeplinește cumulativ trei condiții: este un șir nevid, prezintă un scor de confidență de minimum 0.4 și respectă strict formatul impus. Rezultatele

incorect formatate (provenite, în general, din erori ale modulului OCR) sunt astfel filtrate anterior etapei de evaluare, contribuind la o creștere semnificativă a robusteții rezultatului final.

5.3.8 Votarea temporală

Determinarea rezultatului final pentru o traiectorie se realizează printr-un proces de *selecție majoritară* aplicat pe istoricul citirilor valide. Această logică de agregare, integrată în metoda `PlateTracker.update()`, se declanșează exclusiv după ce instanța de urmărire a înregistrat un minim de `min_votes=3` citiri. Datele candidate sunt centralizate utilizând o structură de tip `Counter`, în cadrul căreia fiecare text cumulează suma scorurilor de confidență aferente. Șirul de caractere cu scorul total maxim este desemnat câștigător; dacă numărul recunoașterilor individuale care îl susțin atinge pragul `min_votes`, acesta devine rezultatul consolidat (starea `emitted`) al traiectoriei, având un scor de confidență final calculat ca media aritmetică a scorurilor individuale.

Interogarea bazei de date este inițiată strict după ce o traiectorie generează o citire stabilizată: funcția `lookup_owner_by_plate()` verifică existența unui proprietar, iar validarea unei înregistrări atestă statutul de vehicul autorizat. Plăcuțele aflate în stadiu de evaluare sau care nu figurează în sistem sunt etichetate drept UNKNOWN (sau "Unknown car"). La nivelul interfeței vizuale, vehiculele autorizate sunt delimitate printr-o casetă verde, în timp ce vehiculele neautorizate sau necunoscute sunt marcate cu roșu. Acest mecanism de agregare temporală garantează că o plăcuță este validată și supusă verificării doar atunci când există un consens pe mai multe cadre consecutive asupra aceluiași text, eliminând astfel cu succes erorile de citire tranzitorii.

5.4 Modulul de detecție foc și fum

Modulul de detecție a focului și a fumului identifică în fluxul video apariția flăcărilor și a emisiilor de fum, facilitând declanșarea unor alerte timpurii în scenariile de incendiu. Acesta este implementat în clasa `FireDetectionSystem` din fișierul `fire_detection_system.py` și operează într-un fir de execuție dedicat (*Thread 4*).

Provocarea principală a acestui modul nu constă în detecția propriu-zisă, ci în controlul strict al rezultatelor fals pozitive: focul și, în special, fumul, reprezintă categorii vizuale cu un grad ridicat de ambiguitate (fiind predispuse la confuzii cu pereți gri, formațiuni noroase, abur, reflexii calde sau lumina apusului). O detecție primară obținută de la un model YOLO, dacă ar fi utilizată direct pentru declanșarea unei alarme, ar genera un volum inacceptabil de avertizări false. Din acest motiv, implementarea suprapune peste modelul de bază un *mechanism de filtrare structurat pe cinci niveluri*, care transformă detecțiile candidate în alerte finale exclusiv după ce acestea îndeplinesc, în ordine succesivă, condițiile tuturor filtrelor. Subcapitolele următoare descriu modelul de

bază, cele cinci etape de filtrare și, în final, semnificația indicatorilor de stare **confirmed** și **alert** asociați fiecărei detecții.

5.4.1 Modelul YOLOv10 pre-antrenat

Modelul de bază utilizat este TommyNgx/YOLOv10-Fire-and-Smoke-Detection, o variantă a arhitecturii YOLOv10 publicată pe platforma HuggingFace și antrenată specific pentru cele două clase de interes: **Fire** și **Smoke**. Modelul este integrat în sistem în forma sa originală, nefiind necesară o etapă suplimentară de reantrenare (*fine-tuning*), și este instanțiat prin intermediul clasei YOLO (din pachetul *ultralytics*) pe baza fișierului de ponderi `models/fire_and_smoke/best.pt`. Imediat după încărcare, denumirile claselor sunt normalizate prin convertirea literelor în minuscule (**fire**, **smoke**), asigurând astfel o utilizare consecventă în restul fluxului de prelucrare.

La nivelul fiecărui cadru, metoda `process_frame()` execută funcția `model.predict()` utilizând un prag de confidență egal cu *cea mai mică* valoare dintre pragurile definite per clasă, alături de un prag IoU de 0.45 pentru algoritmul de suprimare a non-maximelor (NMS). Această abordare a fost aleasă în mod deliberat: modelului i se permite să returneze toate detecțiile candidate care depășesc pragul minim de confidență, urmând ca filtrarea riguroasă la nivel de clasă să fie aplicată ulterior, în mod explicit, de către mecanismul de procesare. Această arhitectură oferă un control deplin asupra procesului decizional de declanșare a alertelor.

5.4.2 Pipeline-ul de filtrare în cinci niveluri

Fiecare rezultat candidat furnizat de modelul YOLOv10 parcurge, în mod secvențial, cinci niveluri de filtrare. Pentru ca o detecție să fie validată și transformată în alertă, aceasta trebuie să îndeplinească cerințele tuturor celor cinci etape; neîndeplinirea criteriilor la oricare dintre aceste niveluri atrage respingerea automată a detecției (sau, în cazul specific al filtrului temporal, reținerea acesteia în starea de detecție aflată în curs de confirmare). Sistemul menține o serie de statistici interne (precum `rejected_by_size`, `rejected_by_color` etc.) pentru a contoriza cu precizie numărul detecțiilor invalidate la nivelul fiecărui filtru.

5.4.2.1 Praguri de încredere per clasă

Primul nivel aplică un prag de încredere *diferențiat pe clasă*: 0.40 pentru **fire** și 0.55 pentru **smoke**. Pragul mai sever pentru fum reflectă faptul că acesta este semnificativ mai predispus la false pozitive (suprafețe gri, nori, abur) decât focul, care are o semnătură vizuală mai distinctivă. O detecție a cărei încredere este sub pragul clasei sale este eliminată imediat.

5.4.2.2 Filtre de dimensiune

Cel de-al doilea nivel de filtrare evaluează plauzibilitatea dimensională a casetei de încadrare, raportând suprafața acesteia la aria totală a cadrului. Sunt res-

pinse atât detecțiile cu o suprafață neglijabilă (sub 0.3% din imagine, care reprezintă de obicei zgomot vizual sau reflexii punctuale), cât și cele disproporționate de mari (peste 85% din cadru, indicând tipic o clasificare eronată care se extinde pe aproape întreaga suprafață vizuală). Astfel, sunt validate și transmise etapei următoare exclusiv detecțiile a căror arie relativă se încadrează în intervalul matematic $[0,003, 0,85]$.

5.4.2.3 Verificarea cromatică HSV

Cel de-al treilea nivel de filtrare constă într-o verificare cromatică euristică, implementată prin intermediul metodei `_color_plausible()`. Aceasta operează în spațiul de culoare HSV, exploatând faptul că focul și fumul prezintă semnături cromatice specifice:

- **Foc:** regiunea analizată trebuie să conțină o pondere semnificativă de pixeli cu nuanțe calde, un grad înalt de saturație și o intensitate luminoasă ridicată. Mai exact, se caută valori ale nuanței (*hue*) din spectrul roșu-portocaliu-galben (situat în intervalele $h \leq 25$ sau $h \geq 160$, compensând astfel dispunerea circulară a valorilor de nuanță în jurul originii), asociate cu o saturație $s \geq 90$ și o luminozitate $v \geq 120$. Condiția de validare impune ca minimum 12% din pixelii regiunii să îndeplinească aceste criterii;
- **Fum:** regiunea trebuie să se caracterizeze printr-o saturație redusă și o luminozitate moderată. Prin urmare, cel puțin 55% din pixeli trebuie să aparțină spectrului cenușiu (având o saturație $s \leq 60$ și o luminozitate $v \geq 40$, limită inferioară impusă pentru a exclude zonele de umbră absolută). Suplimentar, abaterea standard a canalului de luminozitate trebuie să depășească valoarea de 6, o constrângere menită să respingă suprafețele cu o cromatică perfect uniformă (precum cerul senin sau un perete neted), în cadrul cărora un nor de fum real ar induce, în mod inerent, o variație a intensității.

Detecțiile care nu satisfac profilul cromatic specific clasei prezise sunt respinse automat. Această etapă elimină o proporție considerabilă a rezultatelor fals pozitive care ar fi putut valida primele două niveluri de filtrare.

5.4.2.4 Confirmarea temporală prin tracking IoU

Cel de-al patrulea nivel de filtrare impune o condiție de persistentă temporală: o detecție devine *confirmată* exclusiv dacă este identificată în mod constant pe parcursul a cel puțin 6 cadre consecutive. Pentru a asigura trasabilitatea unei detecții între cadre succesive, metoda `_update_frame_history()` corelează caseta de încadrare curentă cu înregistrările din istoricul temporal, utilizând ca metrică suprapunerea spațială ($\text{IoU} \geq 0,3$, calculată prin funcția `_compute_iou()`), cu obligativitatea apartenenței la aceeași clasă. În cazul identificării unei corespondențe, contorul de apariții consecutive al înregistrării este incrementat; în caz contrar, sistemul inițializează o intrare nouă, având

contorul setat la valoarea 1. Instanțele care nu mai sunt detectate în cadrul analizat sunt invalidate și eliminate din istoric, întrerupând astfel continuitatea secvenței. Acest mecanism exclude cu succes detecțiile efemere (cum ar fi scîlpirile luminoase de scurtă durată sau artefactele de compresie video), care apar izolat și nu pot indica prezența unui incendiu real.

5.4.2.5 Cooldown de alertă pe locație

Cel de-al cincilea nivel de filtrare previne saturarea sistemului cu alerte redundante generate de același eveniment. Odată ce o detecție dobândește starea de *confirmată*, o nouă alertă este emisă exclusiv dacă a expirat un interval de timp prestabilit de la ultima notificare asociată *aceleiași locații*. Identificarea spațială este aproximată printr-o cheie de indexare simplificată, construită din eticheta clasei și coordonatele punctului de origine, divizate printr-o împărțire întreagă la un factor de 40 (`class_name_x1//40_y1//40`). Această cuantificare a spațiului asigură faptul că detecțiile care prezintă fluctuații minore de poziție sunt atribuite aceleiași surse. Intervalul minim de latență între două alerte consecutive pentru o locație identică este setat la 3 secunde. Prin această metodă, un eveniment persistent declanșează o alertă inițială, urmată de notificări recurente controlate, evitându-se astfel o suprasarcină de avertizări la procesarea fiecărui cadru.

5.4.3 Flag-urile *confirmed* și *alert*

Fiecare predicție returnată de metoda `process_frame()` este însoțită de doi indicatori de stare (valori booleene), care codifică rezultatul fluxului de filtrare și care îndeplinesc roluri funcționale distincte:

- **confirmed**: capătă valoarea de adevăr atunci când detecția a validat primele patru niveluri și a atins pragul de persistență temporală (minimum 6 cadre consecutive). O astfel de predicție este tratată drept un eveniment real și este *reprezentată grafic* pe cadru; rezultatele candidate neconfirmate sunt ascunse, prevenind astfel fluctuația vizuală (afișarea intermitentă) a casetelor incerte;
- **alert**: este evaluat ca adevărat exclusiv în cadrul în care o predicție confirmată îndeplinește și condiția intervalului de latență, semnalând momentul exact pentru declanșarea unei *alarme* (spre exemplu, înregistrarea în baza de date și transmiterea unei notificări prin protocolul WebSockets). La nivelul interfeței, o detecție marcată prin indicatorul **alert** este evidențiată printr-un chenar îngroșat, fiind însoțită de un mesaj de avertizare de tipul **FIRE ALERT** suprapus pe cadru.

Această decuplare a indicatorilor separă *starea* sistemului (prezența validată a focului sau a fumului în cadrul curent) de *evenimentul* de notificare (necesitatea declanșării imediate a unei alarme). Abordarea permite afișarea continuă a focurilor confirmate, eliminând totodată riscul generării unor alerte redundante.

5.5 Modulul de detecție a armelor (model fine-tuned propriu)

Spre deosebire de componentele anterioare, care integrează modele pre-antrenate în forma lor originală, modulul dedicat detecției de arme se fundamentează pe o arhitectură YOLOv8 reantrenată (*fine-tuned*) integral în cadrul acestui proiect, utilizând un set de date construit special pentru această sarcină. Această decizie a fost motivată de absența unui model public suficient de robust pentru identificarea generică a armelor în scenariile de supraveghere video. Prezenta secțiune detaliază întregul flux de dezvoltare, pornind de la deciziile de proiectare (precum definirea unei singure clase de interes și selecția arhitecturii de bază), continuând cu etapa de colectare și uniformizare a setului de date, și finalizându-se cu parametrizarea procesului de antrenare și evaluarea rezultatelor obținute. Fluxul de antrenare este structurat modular în trei scripturi, executate secvențial: `01_download_datasets.py`, `02_relabel_and_merge.py` și `03_train_yolo.py`.

5.5.1 Justificarea unei singure clase *weapon*

Modelul este antrenat să recunoască o singură clasă generică, **weapon**, care acoperă deopotrivă arme de foc (pistoale, puști), arme albe (cuțite, macete) și obiecte contondente (bâte de baseball). Decizia de a grupa toate tipurile de arme într-o singură clasă este motivată practic: în contextul unui sistem de supraveghere, ceea ce contează este *prezența* unei arme în cadru, nu categoria ei exactă. Această abordare reduce problema de clasificare la una de detecție binară (armă / non-armă), permite modelului să generalizeze mai bine pe date noi și elimină confuziile între subtipuri de arme, care oricum ar declanșa același tip de alertă.

5.5.2 Selectarea modelului de bază

Modelul de bază ales pentru antrenarea suplimentară (*fine-tuning*) este **YOLOv8m** (varianta *medium*), pre-antrenat pe setul de date COCO. Această variantă oferă un echilibru bun între acuratețe și viteză de inferență: este suficient de complexă pentru a învăța formele variate ale armelor, dar suficient de ușoară pentru a rula în timp real, alături de celelalte modele, pe același GPU. Procesul pornește de la ponderile COCO (`pretrained=True`), beneficiind astfel de trăsăturile vizuale generice deja învățate, pe baza cărora detectorul se adaptează la noua clasă.

5.5.3 Dataseturile utilizate

Deoarece niciun set de date public nu oferea, în mod individual, o acoperire suficientă pentru diversitatea tipurilor de arme, a condițiilor de iluminare și a perspectivelor necesare, s-a decis combinarea a două seturi de date

independente. Acestea au fost preluate automat prin intermediul scriptului `01_download_datasets.py`:

- **Dangerous Items** (Zenodo) – 8.478 de imagini, cu cinci clase originale, toate arme: `machete`, `knife`, `baseball_bat`, `rifle` și `gun`. Imaginile acoperă scene diverse, de la arme prezentate izolat până la arme ținute în mână;
- **SOHAS Weapon Detection** (Roboflow) – 5.858 de imagini, cu șase clase originale: `pistol`, `knife`, `smartphone`, `billete` (bancnote), `monedero` (portofel) și `tarjeta` (card). Ultimele patru clase sunt obiecte non-armă care pot fi ușor confundate cu arme și ajută modelul să învețe să le diferențieze.

După combinare, datasetul final conține 14.336 de imagini și 12.592 de bounding box-uri, oferind o diversitate suficientă pentru antrenarea unui detector robust.

5.5.4 Preprocesarea și unificarea

Cele două dataseturi folosesc scheme de etichetare diferite, astfel încât a fost necesară o etapă de preprocesare pentru unificarea lor într-o structură YOLO coerentă, realizată de scriptul `02_relabel_and_merge.py`. Operațiile principale sunt:

- **Relabel** – toate clasele de arme din ambele dataseturi sunt remapate la clasa unică 0 (`weapon`). În cazul Zenodo, toate cele cinci clase sunt arme, deci toate sunt păstrate; în cazul Roboflow, doar `pistol` și `knife` sunt păstrate, iar clasele non-armă (`smartphone`, `billete`, `monedero`, `tarjeta`) sunt *eliminate* din etichete;
- **Merge** – cele două dataseturi sunt unite într-o singură structură YOLO cu trei partiții (`train`, `valid`, `test`); partiția `val` a sursei Zenodo este redenumită `valid` pentru consistență;
- **Negative samples** – imaginile fără adnotări (în care nu apare nicio armă) sunt păstrate ca exemple negative. Ele învață modelul ce *nu* este o armă și reduc rata de false pozitive la inferență, mai ales pentru obiectele care seamănă cu armele (cazul imaginilor cu telefoane sau portofele din Roboflow, ale căror etichete au fost golite).

La final, scriptul generează automat un fișier `data.yaml` cu structura standard YOLO, declarând o singură clasă (`nc: 1, names: {0: weapon}`).

5.5.5 Strategia de denumire (`zen_ / rf_`)

O problemă subtilă la unirea a două dataseturi este coliziunea numelor de fișiere: ambele surse pot conține, de exemplu, o imagine numită `0001.jpg`, care s-ar

suprascrisie reciproc la copierea în directorul comun. Pentru a o evita, fiecărei imagini și etichete i se adaugă un prefix în funcție de sursă: **zen_** pentru imaginile din Zenodo și **rf_** pentru cele din Roboflow. Astfel, perechile imagine-etichetă rămân corelate (același prefix și același nume de bază), iar fișierele celor două surse coexistă fără pierderi în arborele **train/valid/test** comun.

5.5.6 Parametrii de antrenare

Antrenarea propriu-zisă, realizată de scriptul `03_train_yolo.py`, a folosit următorii parametri principali:

- **Epoci:** 100 de epoci planificate, cu *early stopping* (**patience=20**) – oprire automată dacă metrica de validare nu se mai îmbunătățește timp de 20 de epoci;
- **Batch size:** 16 imagini per batch;
- **Rezoluția de intrare:** 640×640 pixeli, valoarea standard pentru YOLOv8;
- **Optimizer:** AdamW, cu learning rate inițial $lr_0 = 0,001$ și factor final $lr_f = 0,01$, conform unei programări cosinus a ratei de învățare (**cos_lr=True**), și **weight_decay** = 0,0005;
- **Warmup:** 3 epoci de warmup pentru stabilizarea gradientilor la începutul antrenării.

Scriptul include și o rutină de selecție automată a GPU-ului cu cea mai multă memorie liberă (`pick_gpu()`, via `pynvml` sau, în lipsa lui, `nvidia-smi`). Antrenarea a fost realizată pe un GPU NVIDIA A100.

5.5.7 Augmentările folosite

Pentru a crește robustețea modelului și a reduce overfitting-ul, în timpul antrenării au fost aplicate multiple transformări de augmentare a datelor:

- **Variații cromatice HSV** – nuanță ($\pm 0,015$), saturație ($\pm 0,7$) și luminositate ($\pm 0,4$), pentru a simula condiții de iluminare diferite;
- **Transformări geometrice** – rotație până la 10° , translație de 10%, scalare de 50% și oglindire orizontală (**fliplr=0.5**);
- **Mosaic** (**mosaic=1.0**) – combinarea a patru imagini într-una singură, expunând modelul la contexte și scale variate;
- **MixUp** (**mixup=0.1**) – amestecarea a două imagini, ca regularizare suplimentară.

5.5.8 Rezultatele antrenării

Antrenarea a parcurs toate cele 100 de epoci (early stopping nu s-a declanșat). Metricile pe partiția de validare la finalul antrenării sunt sintetizate în tabelul 5.1.

Tabel 5.1: Metricile finale de validare ale modelului de detecție a armelor.

Metrică	Valoare
Precizie (<i>precision</i>)	0,937
Sensibilitate (<i>recall</i>)	0,894
mAP@0,5	0,947
mAP@0,5:0,95	0,700

Modelul atinge o precizie de 93,7% și o sensibilitate de 89,4%, cu un mAP@0,5 de 0,947. Valoarea mAP@0,5:0,95 (media mAP peste praguri IoU de la 0,5 la 0,95) este de 0,700, indicând o localizare bună, deși mai puțin precisă la pragurile IoU foarte stricte – comportament tipic pentru detecția unor obiecte cu forme și orientări foarte variate, cum sunt armele.

5.5.9 Discuție asupra rezultatelor

Valorile obținute sunt solide pentru o sarcină dificilă: detecția unei clase vizual eterogene (o armă de foc, un cuțit și o bătă de baseball au foarte puține trăsături comune), pe un dataset combinat din surse cu stiluri de adnotare diferite. Diferența dintre precizie (93,7%) și sensibilitate (89,4%) arată că modelul este ușor mai conservator: ratează unele arme, dar generează relativ puține detecții false – un compromis dezirabil pentru a evita alarmele false într-un sistem de securitate.

Acest comportament este întărit la inferență de o decizie de proiectare la nivelul modului de rulare (**WeaponDetectionSystem**): deși modelul produce candidați peste un prag de încredere permisiv (0,3), o detecție este reținută doar dacă depășește un post-filtru strict de încredere (0,7), iar alerta este confirmată temporal pe mai multe cadre consecutive (mecanism analog celui de la detecția de foc, secțiunea ??). Astfel, sensibilitatea brută a modelului este deliberat schimbată pe o precizie operațională mai mare, prioritizând reducerea falselor alarme. Aportul exemplelor negative (telefoane, portofele, carduri din SOHAS, cu etichete golite) se reflectă tocmai în această precizie ridicată, modelul fiind expus explicit la obiecte care pot fi confundate cu arme.

5.6 Modulul de recunoaștere a acțiunilor umane (fine-tuning SlowFast)

Cel mai complex modul de inteligență artificială al sistemului este cel de recunoaștere a acțiunilor umane (HAR – *Human Action Recognition*), care clasifică *secvențe*

video (nu cadre izolate) în trei categorii comportamentale: **normal** (activitate obișnuită), **fight** (lupte, altercații fizice) și **vandalism** (acte de distrugere intenționată a proprietății). Spre deosebire de detectoarele de obiecte, care operează pe un singur cadru, recunoașterea acțiunilor necesită modelarea dimensiunii temporale – aceeași imagine poate aparține atât unei îmbrățișări, cât și unei altercații, distincția fiind dată de mișcare.

Acest modul reprezintă, alături de detectorul de arme, una dintre cele două componente antrenate în cadrul proiectului. Antrenarea (fine-tuning) a fost realizată în proiectul separat **security_system**, iar modelul rezultat este consumat de aplicația principală ca un fișier checkpoint (**best_model.pth**), încărcat la rulare de clasa **HumanActionRecognitionSystem** din **har_system.py** (*Thread 5*). Subcapitolele care urmează descriu alegerea arhitecturii, construcția setului de date (inclusiv crearea de la zero a unui dataset propriu pentru clasa **vandalism**), procesul de fine-tuning, parametrii și rezultatele, iar la final modul de integrare în aplicație.

5.6.1 Justificarea alegerii SlowFast R50

Arhitectura aleasă este **SlowFast R50**, dezvoltată de Facebook AI Research, ale cărei fundamente au fost prezentate în secțiunea 3.6.2. Ea se bazează pe două căi de procesare paralele: o cale *Slow*, care procesează puține cadre la rezoluție temporală redusă și captează informația semantică spațială, și o cale *Fast*, care procesează multe cadre și captează dinamica mișcării, cele două fiind unite prin conexiuni laterale. Această separare explicită a aspectului spațial de cel temporal o face deosebit de potrivită pentru distingerea acțiunilor pe baza mișcării – exact problema de față.

Varianta R50 (cu backbone ResNet-50) oferă un compromis bun între capacitate și cost computațional, permițând inferența în timp real alături de celelalte modele. În plus, modelul este disponibil pre-antrenat pe datasetul Kinetics-400 (prin PyTorchVideo / PyTorch Hub), ceea ce oferă un punct de pornire solid: reprezentările video generice învățate pe 400 de clase de acțiuni pot fi adaptate prin fine-tuning la cele trei clase ale problemei, cu un set de date mult mai mic decât ar fi necesar pentru antrenarea de la zero.

5.6.2 Construcția setului de date

Setul de date pentru fine-tuning a fost construit din trei surse, câte una pentru fiecare clasă. Structura este de tip folder-per-clasă (**data/train/<clasă>/** și **data/test/<clasă>/**), iar clasele sunt descoperite automat din numele folderelor de către **configs/config.py**, cu convenția ca eticheta **normal** să primească întotdeauna indexul 0.

5.6.2.1 Clasa *normal*

Clasa **normal** conține videoclipuri de supraveghere cu activitate cotidiană, fără incidente, preluate din datasetul public **RWF-2000** (disponibil pe Kaggle).

Aceste secvențe oferă modelului o referință pentru ceea ce înseamnă comportament obișnuit, esențială pentru a delimita clasele de interes (**fight**, **vandalism**) de fundalul normal.

5.6.2.2 Clasa *fight*

Clasa **fight** conține videoclipuri cu lupte și altercații fizice, preluate tot din datasetul **RWF-2000**, care include scene de confruntare fizică între persoane, capturate de camere de supraveghere. Folosirea aceluiași dataset pentru clasele **normal** și **fight** asigură un stil vizual consistent (rezoluție, unghiuri, calitate a imaginii) între cele două, astfel încât modelul să învețe diferența de *acțiune*, nu de domeniu vizual.

5.6.2.3 Clasa *vandalism* – dataset propriu

5.6.2.3.1 Justificarea creării unui dataset propriu. Spre deosebire de primele două clase, pentru **vandalism** nu există un dataset public adecvat de videoclipuri de supraveghere. Din acest motiv, a fost necesară construirea unui set de date propriu, de la zero, printr-un proces în trei etape descris în continuare.

5.6.2.3.2 Etapa 1: Scraping automat YouTube. A fost dezvoltat un script Python dedicat care folosește biblioteca **yt-dlp** pentru a căuta și colecta automat link-uri către videoclipuri candidate de pe YouTube. Scriptul generează sute de interogări de căutare variate, în mai multe limbi, acoperind acte specifice de vandalism (graffiti, spargere de geamuri, distrugere de mașini, intrare prin efracție etc.) combinate cu termeni asociați camerelor de supraveghere. În urma acestui proces au fost colectate aproximativ 4.800 de link-uri către potențiale videoclipuri.

5.6.2.3.3 Etapa 2: Filtrare manuală. Toate cele aproximativ 4.800 de videoclipuri au fost vizualizate și evaluate manual, pentru a selecta doar clipurile care conțin efectiv acte de vandalism filmate de camere de supraveghere, eliminându-le pe cele irelevante. În urma filtrării au rămas peste 600 de videoclipuri valide. Această etapă, deși laborioasă, este esențială pentru calitatea datasetului: garantează că modelul învață din exemple reale și relevante.

5.6.2.3.4 Etapa 3: Editare în OpenShot. Videoclipurile selectate au fost editate individual cu software-ul OpenShot Video Editor, pentru a extrage doar segmentele relevante. Fiecare clip a fost decupat astfel încât să conțină secvența propriu-zisă a actului de vandalism, eliminând porțiunile irelevante (intro-uri, text suprapus, secvențe fără activitate).

5.6.2.3.5 Setul final. Setul de date final pentru clasa **vandalism** conține **614 videoclipuri** cu acte de vandalism, acoperind o gamă largă de acțiuni: graffiti / street art, spargere de geamuri și vitrine, distrugere de autoturisme

(zgâriere, lovire), intrare prin efracție, distrugere de mobilier urban, aruncare cu obiecte și alte forme de distrugere intenționată a proprietății.

5.6.3 Pregătirea modelului pentru fine-tuning

Pregătirea modelului pornește de la SlowFast R50 pre-antrenat pe Kinetics-400, al cărui cap de clasificare original – un strat `Linear(2304, 400)` corespunzător celor 400 de clase Kinetics – este înlocuit cu un cap nou, adaptat problemei: o secvență `Dropout(0.5)` urmată de un `Linear(2304, 3)`, pentru cele trei clase. Această înlocuire este realizată în `build_slowfast_model()` din `models/slowfast_model.py`.

5.6.3.1 Formatul intrării (contractul SlowFast)

Fiecare videoclip este transformat într-o pereche de tensori, câte unul pentru fiecare cale: calea Slow primește 8 cadre, iar calea Fast 32 de cadre, ambele decupate spațial la 224×224 pixeli. Cadrele sunt eșantionate uniform dintr-un clip corespunzător unei durate de 2.0 secunde. Aceste valori sunt fixate în `configs/config.py` și trebuie respectate identic la inferență (în aplicație), altfel modelul ar primi intrări incompatibile cu cele pe care a fost antrenat.

5.6.4 Parametrii de antrenare

Antrenarea, implementată în `train.py`, folosește o strategie de fine-tuning în *două faze*, gândită pentru a adapta modelul la noile clase fără a distruge reprezentările pre-antrenate:

- **Faza 1 – backbone înghețat** (primele 5 epoci): toți parametrii backbone-ului sunt înghețați (`requires_grad=False`), antrenându-se *doar* capul de clasificare nou. Astfel, capul aleator inițializat se stabilizează fără a perturba caracteristicile vizuale învățate pe Kinetics-400;
- **Faza 2 – fine-tuning complet**: backbone-ul este dezghețat și întregul model este antrenat, dar cu *rate de învățare diferențiate* – backbone-ul primește o rată de 10 ori mai mică decât capul (`lr_backbone_factor=0.1`), pentru a-l ajusta fin fără a-l deteriora.

Alți parametri și tehnici folosite, conform `config.py` și `train.py`:

- **Optimizator**: AdamW, rată de învățare 10^{-3} , `weight_decay = 10^{-4}`, cu o programare de tip StepLR (reducere de $10\times$ la fiecare 10 epoci);
- **Funcția de pierdere**: CrossEntropyLoss cu *label smoothing* de 0,1, pentru a reduce supraîncrederea modelului;
- **Dezechilibrul de clase**: tratat printr-un `WeightedRandomSampler`, care eșantionează clasele invers proporțional cu frecvența lor, astfel încât fiecare clasă să fie reprezentată echilibrat în batch-uri;

- **Tehnici de stabilizare:** antrenare în precizie mixtă (AMP, prin `GradScaler` și `autocast`), *gradient clipping* la norma maximă 5,0 și *early stopping* (răbdare de 7 epoci) bazat pe macro-F1 de validare;
- **Augmentare spațială:** oglindire orizontală, *color jitter* și *random crop*.

Din cele 30 de epoci planificate, antrenarea s-a oprit la epoca 28 prin early stopping, cele mai bune rezultate (cele salvate ca `best_model.pth`) fiind obținute la epoca 21. Antrenarea a folosit 262 de batch-uri pe epocă la antrenare și 56 la validare, cu o durată medie de aproximativ 15 minute per epocă.

5.6.5 Rezultatele

Metricile globale obținute pe setul de validare de către modelul cel mai bun (epoca 21) sunt sintetizate în tabelul 5.2. Pierderea finală de antrenare a fost de 0,3065, iar cea de validare de 0,4306.

Tabel 5.2: Metricile globale de validare ale modelului de recunoaștere a acțiunilor.

Metrică	Valoare
Acuratețe (<i>accuracy</i>)	0,9433
Macro Precision	0,9478
Macro Recall	0,9436
Macro F1-Score	0,9456

Modelul atinge o acuratețe globală de 94,33% și un macro F1-score de 94,56%, valori foarte bune pentru o problemă de clasificare a acțiunilor pe trei clase, în condiții de supraveghere reale.

5.6.6 Analiza per clasă

Rezultatele detaliate pe fiecare clasă sunt prezentate în tabelul 5.3.

Tabel 5.3: Metricile per clasă ale modelului de recunoaștere a acțiunilor.

Clasă	Precision	Recall	F1-Score	Suport
normal	0,920	0,947	0,933	169
fight	0,942	0,935	0,939	155
vandalism	0,982	0,949	0,965	117

Se remarcă faptul că tocmai clasa **vandalism** – cea pentru care a fost construit datasetul propriu – obține cele mai bune rezultate, cu o precizie de 98,2% și un F1-score de 0,965. Acest rezultat validează efortul de creare a datasetului custom: clipurile selectate și editate manual sunt suficient de curate și de reprezentative pentru ca modelul să învețe robust această clasă. Clasele **normal**

și **fight** obțin de asemenea scoruri ridicate (F1 de 0,933, respectiv 0,939), confuziile reziduale fiind, în mod așteptat, preponderent între ele – ambele provin din același dataset RWF-2000 și pot conține secvențe ambigue la granița dintre activitate agitată și altercație.

5.6.6.1 Integrarea în aplicație

La rulare, modelul antrenat este folosit de `HumanActionRecognitionSystem`, care nu poate clasifica un singur cadru, ci are nevoie de o secvență. De aceea, sistemul acumulează cadrele primite într-un *ring buffer* (`deque`) și rulează inferența doar o dată la fiecare 30 de cadre (`clip_interval_frames`), atunci când bufferul conține destule cadre. La fiecare inferență, se eșantionează uniform până la 64 de cadre din buffer, se construiește perechea *slow/fast* ($8/32$ cadre, 224×224) exact ca la antrenare, se aplică **softmax** peste logits și se reține clasa cu probabilitatea maximă. O acțiune non-normală este raportată ca alertă doar dacă încrederea depășește pragul `confidence_threshold` (0,5), cu un *cooldown* de alertă de 5 secunde pentru a evita notificările repetate. Predicția curentă este păstrată între inferențe, astfel încât adnotarea afișată pe flux rămâne coerentă chiar și pe cadrele dintre două rulări de inferență.

5.7 Fuziunea rezultatelor pe cadru

Cele cinci module de inteligență artificială descrise anterior nu rulează izolat, ci sunt orchestrate de aplicația principală (`app.py`) într-un *pipeline multi-threaded* care procesează același flux video în paralel și apoi recombina rezultatele într-un singur cadru adnotat. Această secțiune descrie modul în care detecțiile provenite de la modele diferite, care rulează pe fire de execuție separate și se termină la momente diferite, sunt sincronizate, suprapuse pe cadru, transformate în alarme și difuzate către clienți.

Decizia arhitecturală fundamentală este aceea de a folosi *fire de execuție* (**threading**) cu cozi (`queue.Queue`), nu programare asincronă: apelurile de inferență ale modelelor sunt operații blocante, intensive computational, care nu trebuie să blocheze bucla de evenimente a serverului FastAPI. Pipeline-ul folosește în total **șapte fire de execuție**: captură (Thread 1), recunoaștere facială cu demografie (Thread 2), plăcuțe (Thread 3), foc și fum (Thread 4), acțiuni umane (Thread 5), arme (Thread 6) și un fir final de fuziune (Thread 7).

5.7.1 Dispecerizarea cadrelor și procesarea în paralel

Firul de captură (Thread 1) citește cadre de la toate camerele active (camera laptop-ului și eventualele camere IP). Fiecărui cadru *i* se atribuie un identificator unic și monoton crescător, `frame_id`, care va servi drept cheie de sincronizare pe tot parcursul pipeline-ului. Cadrul este apoi *dispecerizat* de metoda `_dispatch_frame()`, care îi pune câte o copie în coada de intrare a fiecărui modul activat (`face_processing_queue`, `plate_processing_queue` etc.) și,

separat, în coada de cadre brute (`raw_frame_queue`), care păstrează imaginea originală pentru recompunere.

Fiecare modul AI rulează în propriul fir, consumând cadre din coada sa, executând inferența și publicând rezultatele în coada sa de ieșire (`face_results_queue` etc.). Cum cozile au capacitate mărginită (`maxsize=10`), atunci când un modul lent nu mai poate prelua cadre, dispecerul nu blochează, ci sare peste cadru (incrementând un contor de `queue_skips` / `frames_dropped`). Astfel, un model mai lent degradează elegant rata de cadre, fără a opri întregul sistem.

5.7.2 Sincronizarea rezultatelor după *frame_id*

Firul de fuziune (Thread 7) are sarcina dificilă de a recombina rezultate care sosesc *asincron*: modulul de plăcuțe poate termina cadrul N înainte ca modulul facial să termine cadrul $N - 2$. Pentru aceasta, firul menține un dicționar `pending_results`, cu câte o intrare pentru fiecare tip de rezultat (`frames`, `face`, `plate`, `fire`, `har`, `weapon`), indexată după `frame_id`. La fiecare iterație, firul golește toate cozile de rezultate disponibile în acest dicționar, apoi încearcă să *asambleze* fiecare cadru pentru care a sosit imaginea brută.

Un cadru este considerat gata de asamblare atunci când rezultatele modulelor *esențiale* activate (recunoaștere facială și plăcuțe) au sosit. Rezultatele modulelor de foc, acțiuni și arme sunt tratate ca *opționale*: ele sunt suprapuse dacă au sosit, dar absența lor nu blochează asamblarea. Pentru a evita blocajul atunci când un rezultat nu mai sosește (de exemplu, din cauza unui cadru sărit), există un mecanism de *timeout*: dacă un cadru devine prea vechi (diferența dintre `frame_id`-ul curent și al lui depășește 60), el este asamblat cu rezultatele disponibile la acel moment, fără a mai aștepta. În plus, o rutină de curățare (`_cleanup_old_results()`) elimină periodic intrările mai vechi de 90 de cadre, pentru ca dicționarul să nu crească nelimitat în caz de desincronizare.

5.7.3 Compunerea cadrului adnotat

Odată ce un cadru este gata de asamblare, adnotările celor cinci module sunt desenate *în straturi* peste imagine, într-o ordine fixă. Punctul de plecare este cadrul deja adnotat de modulul facial (care conține chenarele fețelor și etichetele demografice), peste care se aplică succesiv: chenarele plăcuțelor (`plate_system.draw_outputs()`), detecțiile de foc confirmate (`fire_system.draw_detections()`), eticheta acțiunii recunoscute (`har_system.draw_detections()`) și, la final, chenarele armelor (`weapon_system.draw_detections()`). Rezultatul este un singur cadru (`final_frame`) care concentrează vizual toate detecțiile celor cinci module pentru acel moment de timp.

5.7.4 Generarea alarmelor și deduplicarea

În aceeași etapă de fuziune, detecțiile relevante sunt transformate în două tipuri de înregistrări persistente: *jurnale de detecție* (un istoric complet, scris prin `_log_detection_if_needed()`) și *alarme* propriu-zise (evenimente care

necesită atenția operatorului). Sunt considerate demne de alarmă: persoanele necunoscute, focul confirmat cu **alert**, acțiunile non-**normal**, armele detectate, vehiculele neautorizate (plăcuțe lizibile care nu sunt pe lista albă) și prezența unei persoane neautorizate într-o zonă restricționată.

Problema centrală a generării alarmelor este evitarea inundării operatorului cu duplicate: un foc care arde 10 secunde nu trebuie să genereze o alarmă la fiecare cadru. Mecanismul de deduplicare, implementat în `_create_alarm_if_needed()`, folosește o cheie compusă din cameră, tip și *subiect* (`camera_id:alarm_type:dedup_subject`) și un cooldown de 30 de secunde per cheie. Componenta de subiect este esențială: ea permite ca alarme distincte de *același* tip să coexiste – de exemplu, două persoane necunoscute diferite (diferențiate prin poziție), un cuțit și un pistol, sau două plăcuțe neautorizate diferite – fără a se contopi într-o singură alarmă. Pe lângă bariera din memorie, există și o verificare de rezervă în baza de date (`get_recent_alarm()`), care previne avalanșa de alarme duplicate imediat după o repornire a serverului, când starea de cooldown din memorie este goală.

5.7.5 Difuzarea către clienți prin WebSocket

Ultimul pas al fuziunii este livrarea cadrului asamblat către interfețele clienților. Cadrul `final_frame` este redimensionat (la maximum 800 px lățime), codat JPEG cu o calitate de 75 și convertit în Base64 prin `_encode_and_queue_frame()`. Acesta este împachetat într-un mesaj JSON care conține, pe lângă imagine, listele de rezultate serializate ale tuturor modulelor (`face_results`, `plate_results`, `fire_results`, `har_results`, `weapon_results`), identificatorul camerei, un *timestamp* și starea (activat/dezactivat) a fiecărui modul.

Difuzarea propriu-zisă (`_broadcast_frame()`) folosește un model de tip *fan-out* cu cozi independente per client: fiecare client conectat prin WebSocket are propria coadă de ieșire, iar firul de fuziune publică fiecare cadru procesat în toate cozile. Această izolare este importantă – un client lent își aruncă doar propriul cadru cel mai vechi atunci când coada lui se umple, fără a “fura” cadre de la ceilalți clienți sau a-i încetini. Astfel, fluxul video adnotat ajunge la fiecare operator în mod independent, încheind ciclul de procesare care a pornit de la captura cadrului brut.

NECLASIFICAT

Capitolul 6: Implementarea Aplicației Web

- 6.1 Structura backend-ului FastAPI
- 6.2 Endpoint-ul WebSocket pentru streaming live
- 6.3 Modelul de date și persistența
- 6.4 Sistemul de autentificare
- 6.5 Modulele frontend-ului React
 - 6.5.1 Autentificare
 - 6.5.2 Vizualizarea live a camerelor (Dashboard)
 - 6.5.3 Activarea/Dezactivarea modulelor AI
 - 6.5.4 Gestiunea persoanelor (CRUD)
 - 6.5.5 Gestiunea zonelor
 - 6.5.6 Gestiunea camerelor
 - 6.5.7 Gestiunea plăcuțelor de înmatriculare
 - 6.5.8 Gestiunea alarmelor
 - 6.5.9 Jurnale de activitate
 - 6.5.10 Statistici și KPI-uri
 - 6.5.11 Gestiunea utilizatorilor
- 6.6 Logica de business pentru declanșarea alertelor
- 6.7 Sincronizarea camerei conectate dinamic cu registrul de camere

Capitolul 7: Testarea și Evaluarea Sistemului

7.1 Metodologia de testare

7.2 Configurația hardware folosită

7.3 Evaluarea pipeline-ului integrat

7.3.1 FPS la procesare concurentă

7.3.2 Utilizarea memoriei GPU și RAM

7.3.3 Latența end-to-end

7.4 Scenarii de test funcțional

7.5 Discuție asupra false pozitivelor și false negative

7.6 Limitări observate

Capitolul 8: Concluzii și Direcții de Dezvoltare

- 8.1 Sinteza rezultatelor
- 8.2 Obiective atinse vs. obiective propuse
- 8.3 Contribuții originale
- 8.4 Limitări ale soluției actuale
- 8.5 Direcții de dezvoltare viitoare

Bibliografie

Cărți

Articole Științifice